

федеральное государственное автономное образовательное учреждение высшего образования
Первый Московский государственный медицинский
Университет имени И.М.Сеченова
Министерство здравоохранения Российской Федерации
(Сеченовский Университет)

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

на тему: «Физически-информированная нейронная сеть для оценки
перепада давлений в области сужения просвета сосуда»
(наименование темы)

Направление подготовки 01.04.03 Механика и математическое
моделирование

Студент Осипова Анастасия Андреевна
(Ф.И.О.)

Руководитель Гамилов Тимур Мударисович, кандидат физико-
математических наук, доцент кафедры Высшей математики, механики и
математического моделирования
(уч. степень, уч. звание, Ф.И.О. подпись, дата)

Москва, 2026

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ.....	4
1. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ ОЦЕНКИ ПЕРЕПАДА ДАВЛЕНИЯ ПРИ СТЕНОЗЕ СОСУДОВ	7
1.1 Гемодинамические факторы формирования перепада давления при стенозе	7
1.2 Подходы к оценке перепада давления при стенозе.....	9
1.3 Одномерные модели гемодинамики для описания стеноза	11
1.4 Численное моделирование течения крови в сосуде со стенозом	14
1.5 Методы машинного обучения для предсказания гемодинамических показателей	17
1.6 Нейросетевые модели с физически информированной функцией потерь	18
2. ПОДГОТОВКА ДАННЫХ И ПОСТРОЕНИЕ МОДЕЛЕЙ.....	22
2.1. Описание исходных данных CFD-расчетов.....	22
2.2. Первичный анализ данных (EDA).....	25
2.3 Постановка задачи.....	33
2.3.1 Итоговое признаковое пространство.....	33
2.3.2 Расширенное признаковое пространство	35
2.4 Базовые модели машинного обучения	36
2.4.1 Линейная регрессия	37
2.4.2 Метод ближайших соседей.....	38
2.4.3 Ансамблевые модели на основе деревьев решений	39
2.5 Нейросетевые модели	41
2.5.1 Архитектура нейронной сети.....	42
2.5.2 Полносвязная нейронная сеть.....	43
2.5.3 Физически информированная нейронная сеть.....	44
3. ОЦЕНКА КАЧЕСТВА И ИНТЕРПОЛЯЦИОННОЙ СПОСОБНОСТИ МОДЕЛЕЙ.....	48
3.1 Схема оценки качества моделей	48
3.2. Результаты базовых моделей на тестовой выборке	50
3.3. Результаты нейросетевых моделей на тестовой выборке	54

3.4. Проверка моделей на независимом наборе данных.....	55
4. ИНТЕГРАЦИЯ НЕЙРОННОЙ СЕТИ В ОДНОМЕРНУЮ МОДЕЛЬ ГЕМОДИНАМИКИ	58
4.1. Алгоритм интеграции PINN в одномерный расчет.....	58
4.2. Формирование входа PINN-модуля в одномерном расчете	62
4.3. Численное решение узлового условия	64
4.4. Расчетный эксперимент и сравнение вариантов интеграции	66
ЗАКЛЮЧЕНИЕ	71
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	75

ВВЕДЕНИЕ

Стеноз сосудов представляет собой локальное сужение просвета, при котором изменяются условия движения крови и возрастает гидродинамическое сопротивление пораженного участка. Особое значение стеноз имеет для коронарных артерий, так как нарушение кровоснабжения миокарда может приводить к ишемии и необходимости медицинского вмешательства. При оценке значимости стеноза важно учитывать не только геометрическую степень сужения сосуда, но и его влияние на кровоток, в том числе на перепад давления между участками до и после сужения.

При прохождении крови через область сужения скорость потока возрастает. После выхода из стеноза поток расширяется, распределение скоростей становится менее равномерным. Могут возникать вихревые зоны и дополнительные потери энергии. Поэтому перепад давления зависит не только от степени сужения, но и от режима течения, длины стеноза и формы сосудистого просвета. Одинаковая степень сужения в разных условиях может давать разные значения перепада давления.

Одним из способов исследования гемодинамических процессов является численное моделирование. Вычислительная гидродинамика позволяет получать распределения скорости и давления в сосуде без проведения прямых измерений. Однако подробное численное моделирование требует подготовки геометрии, задания начальных и граничных условий, построения расчетной сетки и вычислительных ресурсов. Для выполнения и анализа таких расчетов необходимы специальные знания.

В связи с этим возникает задача построения приближенных моделей для быстрой оценки перепада давления. Приближенная модель полезна в исследовательских задачах, где требуется сравнивать влияние параметров геометрии сужения и режима течения на итоговый перепад давления.

Отдельное значение имеет учет физических закономерностей при обучении модели. Обычная модель машинного обучения может хорошо

приближать значения на обучающей выборке, но давать противоречащие физическим закономерностям результаты на новых параметрах. В данной работе рассматривается нейронная сеть с физически информированной функцией ошибки. В неё добавляется дополнительная составляющая, связанная с ожидаемым направлением изменения перепада давления при изменении входных признаков. В пределах рассматриваемого диапазона предполагается, что перепад давления должен изменяться согласованно с изменением числа Рейнольдса, степени стеноза, относительной длины стеноза и параметра асимметрии. Это позволяет учитывать не только имеющиеся данные, но и физический смысл решаемой задачи.

Целью выпускной квалификационной работы является разработка и исследование физически информированной нейронной сети для предсказания перепада давления на участке стеноза по результатам CFD-расчетов и интеграция разработанного нейросетевого модуля в одномерную модель гемодинамики.

Объектом исследования является течение вязкой несжимаемой жидкости в идеализированном сосуде с локальным стенозом. Предметом исследования является физически информированная нейронная сеть для предсказания перепада давления на участке стеноза по параметрам течения и геометрии сосуда, а также схема её интеграции в одномерную модель гемодинамики.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Рассмотреть физические причины возникновения перепада давления и основные подходы к его оценке.
2. Описать исходные данные, полученные по результатам CFD-расчетов.
3. Подготовить данные для машинного обучения, включая выбор входных признаков и выходной величины.
4. Построить и обучить базовые модели машинного обучения для получения исходного уровня качества.

5. Обучить нейросетевые модели: обычную полносвязную нейронную сеть и модель с физически информированной функцией ошибки, учитывающей ожидаемое направление изменения целевой величины по входным параметрам.
6. Сравнить качество моделей.
7. Оценить качество моделей на независимом наборе данных, используемом для интерполяционной проверки внутри рассматриваемой расчетной постановки.
8. Реализовать схему интеграции нейросетевого модуля в одномерную модель гемодинамики и провести расчетный эксперимент для сравнения базовой 1D-модели и гибридной схемы 1D + нейросетевой модуль при различных степенях стеноза и параметрах асимметрии.

В работе используются готовые результаты CFD-моделирования течения в сосуде со стенозом. Дополнительно используется независимый набор данных для проверки интерполяции на значениях параметров, отсутствующих в обучающей выборке.

Научная значимость работы заключается в сравнительной оценке моделей и анализ того, влияет ли физически информированная составляющая функции ошибки на качество предсказания и интерполяционную способность нейросетевой модели.

Практическая значимость работы состоит в том, что построенные модели могут использоваться для быстрой приближенной оценки перепада давления в рамках рассматриваемой расчетной постановки. Предложенная схема интеграции нейросетевого модуля в одномерную модель может служить основой для дальнейшего развития гибридных моделей.

1. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ ОЦЕНКИ ПЕРЕПАДА ДАВЛЕНИЯ ПРИ СТЕНОЗЕ СОСУДОВ

1.1 Гемодинамические факторы формирования перепада давления при стенозе

Стеноз сосудов представляет собой локальное уменьшение просвета, при котором изменяются условия кровотока и возрастает гидродинамическое сопротивление пораженного участка. При прохождении потока через суженную область площадь поперечного сечения уменьшается, поэтому скорость в зоне стеноза возрастает. Это следует из закона сохранения массы: при заданном расходе уменьшение проходного сечения приводит к увеличению средней скорости потока. Изменение скорости сопровождается перераспределением механической энергии потока. В зоне сужения часть энергии давления переходит в кинетическую энергию движущейся жидкости, вследствие чего давление в области стеноза снижается. После выхода из суженного участка поток расширяется, однако восстановление давления происходит не полностью. Часть энергии необратимо теряется из-за вязкого трения, отрыва струи, образования зон рециркуляции и нарушения структуры потока за стенозом [1], [2].

Перепад давления на участке стеноза является одним из показателей его функциональной значимости. В отличие от одной только геометрической степени сужения, он характеризует, насколько это сужение влияет на кровоток и сопротивление сосудистого участка. В свою очередь стенозы с близкой степенью уменьшения просвета могут по-разному влиять на движение крови [2], [3], [4].

То есть такое различие связано с тем, что перепад давления формируется под действием нескольких групп факторов. К первой группе относятся параметры режима течения, прежде всего расход крови и связанное с ним число Рейнольдса. Число Рейнольдса характеризует соотношение

инерционных и вязкостных сил в потоке. При его увеличении возрастает роль инерционных эффектов, а при выраженном стенозе это может приводить к более значительным потерям энергии за сужением. Вторая группа факторов связана с геометрией стеноза: степенью сужения, длиной пораженного участка, формой перехода от нормального просвета к области стеноза, а также асимметрией просвета [5], [6].

Степень стеноза является одним из наиболее значимых геометрических параметров. Чем сильнее уменьшена площадь проходного сечения, тем выше скорость в суженной зоне и тем больше потери давления. Однако эта зависимость не является строго линейной. При умеренных сужениях вклад вязкого сопротивления может быть относительно небольшим, тогда как при более выраженных стенозах заметно возрастает роль инерционных и вихревых потерь [5], [7].

Длина стеноза также влияет на итоговые потери давления. С точки зрения гидродинамики сопротивление течению зависит не только от радиуса сосуда, но и от длины участка, на котором поток движется в условиях повышенного сопротивления. Для ламинарного течения в цилиндрическом сосуде сопротивление прямо пропорционально длине участка и обратно пропорционально четвертой степени радиуса [8]. Поэтому более протяженное сужение может увеличивать вклад вязких потерь в общий перепад давления. В исследованиях гемодинамики стенозов длина пораженного участка рассматривается как один из геометрических параметров, влияющих на перепад давления наряду со степенью стеноза и формой сужения [7], [9].

Для сопоставления стенозов разного масштаба удобно использовать не только абсолютную длину, но и безразмерные параметры, например отношение длины стеноза к характерному размеру здорового участка сосуда [7]. Подобные параметры позволяют сравнивать случаи с различным геометрическим масштабом.

Кроме длины стеноза важна форма входа и выхода из суженной области. Она определяет характер ускорения потока перед стенозом и последующего

расширения после него. Резкие переходы могут усиливать отрыв потока и образование вихревых зон, тогда как более плавная геометрия может снижать локальные потери энергии [5], [6].

Отдельное значение имеет асимметрия стеноза. В идеализированной осесимметричной модели поток проходит через сужение относительно равномерно. В реальных сосудах стеноз часто имеет неравномерную форму, поэтому распределение скоростей и давления становится пространственно неоднородным. Асимметрия может приводить к смещению струи, локальному увеличению скорости у одной из стенок и более сложной структуре потока после стеноза. В результате перепад давления зависит не только от степени сужения, но и от формы просвета [6].

Перепад давления при стенозе формируется под действием нескольких взаимосвязанных факторов. Его нельзя однозначно определить только по степени сужения сосуда. Для более содержательной оценки необходимо учитывать режим течения, протяженность стеноза и форму сосудистого просвета.

1.2 Подходы к оценке перепада давления при стенозе

Подходы к оценке перепада давления при стенозе можно условно разделить на эмпирические, аналитические и численные. Они различаются по степени физической детализации, трудоемкости и области применимости. Эмпирические методы удобны для практического использования, аналитические модели позволяют объяснить основные механизмы формирования потерь давления, а численные методы дают возможность учитывать более сложную геометрию и пространственную структуру потока.

К эмпирическим подходам относятся методы, основанные на клинических наблюдениях, экспериментальных данных и упрощенных расчетных зависимостях. Одним из известных примеров является формула Горлина, предложенная для оценки площади стенозированного клапанного

отверстия по расходу крови и градиенту давления [10]. Хотя данная формула была разработана для клапанных стенозов, её значение состоит в том, что она показывает связь между площадью проходного сечения, потоком и перепадом давления.

К группе приближенных клинико-расчетных подходов относится оценка перепада давления по скорости потока, измеренной с помощью доплеровской эхокардиографии. В клинической практике для приближенной оценки градиента давления часто применяют упрощенное уравнение Бернулли, согласно которому перепад давления определяется по максимальной скорости потока [1], [11].

Однако такие методы имеют ограничения. Они основаны на допущениях, которые не всегда выполняются в реальных условиях. Например, упрощенное уравнение Бернулли не учитывает все составляющие потерь энергии, связанные с вязкостью, восстановлением давления и сложной структурой потока после стеноза. Кроме того, результат может зависеть от точности измерения скорости и от выбора направления ультразвукового луча. Поэтому такие методы хорошо подходят только для первичной оценки.

Аналитические подходы связывают перепад давления с параметрами течения и геометрией стеноза. В классических моделях перепад давления представляют как сумму вязкой и инерционной составляющих. Вязкая часть связана с трением и зависит от длины сужения, размеров просвета и вязкости. Инерционная часть возникает из-за ускорения потока в стенозе и последующего расширения за ним; она может усиливаться при отрыве потока и рециркуляции. Однако для сложной геометрии, неравномерного профиля скоростей и зон рециркуляции получение полного аналитического решения становится затруднительным или невозможным [5], [7].

Отдельное место занимают модели пониженной размерности, которые занимают промежуточное положение между простыми аналитическими формулами и полным численным расчетом. Они стремятся сохранить физический смысл основных потерь давления, но при этом уменьшить

вычислительную сложность [7]. К таким подходам относятся одномерные модели гемодинамики, которые подробнее рассматриваются в следующем разделе.

Наряду с приближенными и пониженными моделями существуют трехмерные численные расчеты течения жидкости. Они позволяют получать поля скорости и давления во всем рассматриваемом объеме сосуда, но требуют значительно больших вычислительных затрат. Этот подход подробнее рассматривается в разделе 1.4.

1.3 Одномерные модели гемодинамики для описания стеноза

Одномерные модели гемодинамики применяются для расчета движения крови по сосудистой сети и отдельных участков. В отличие от трехмерных CFD-моделей, они не описывают полное распределение скорости и давления по объему сосуда. Вместо этого рассматриваются усредненные по поперечному сечению скорость потока, расход и давление.

Использование одномерной модели позволяет существенно уменьшить вычислительные затраты. Это особенно важно при моделировании крупных сосудистых сетей, где полный трехмерный расчет для каждого участка был бы слишком трудоемким. В работе Jin и Alastruey отмечается, что 0D- и 1D-модели могут выполняться за секунды или минуты на обычном компьютере, тогда как 3D-моделирование часто требует часов или дней расчета на высокопроизводительных вычислительных системах [12].

В одномерной постановке сосуд рассматривается как упругий трубчатый сегмент, вдоль которого изменяются площадь поперечного сечения $A(x, t)$, скорость $U(x, t)$, расход $Q(x, t)$ и давление $p(x, t)$. Расход связан со скоростью и площадью выражением:

$$Q = AU. \quad (1.3.1)$$

Основу модели составляют уравнения сохранения массы и импульса. Уравнение сохранения массы может быть записано в виде:

$$\frac{\partial A}{\partial t} + \frac{\partial(AU)}{\partial x} = 0. \quad (1.3.2)$$

Это уравнение отражает связь между изменением площади поперечного сечения сосуда во времени и изменением расхода вдоль продольной координаты. Если в участок сосуда поступает больше крови, чем выходит из него, площадь поперечного сечения увеличивается за счет деформации стенки. Если расход на выходе больше, площадь уменьшается.

Уравнение импульса в одномерной модели записывается как

$$\frac{\partial U}{\partial t} + U \frac{\partial U}{\partial x} + \frac{1}{\rho} \frac{\partial p}{\partial x} = \frac{f}{\rho A}, \quad (1.3.3)$$

где ρ – плотность крови, f – член, связанный с вязкими потерями, x – продольная координата сосуда, t – время. Левая часть уравнения описывает нестационарное изменение скорости, конвективное ускорение и влияние градиента давления. Правая часть учитывает потери на трение.

Для замыкания системы используется закон стенки сосуда, который связывает давление и площадь поперечного сечения. Один из вариантов такой зависимости имеет вид:

$$p = p_d + \frac{\beta}{A_d} (\sqrt{A} - \sqrt{A_d}), \quad (1.3.4)$$

где p_d – диастолическое давление, A_d – площадь поперечного сечения при диастолическом давлении, β – параметр жесткости сосудистой стенки. Параметр β зависит от механических свойств стенки: от модуля Юнга E и толщины стенки h :

$$\beta = \frac{4}{3}\sqrt{\pi E h} \quad (1.3.5)$$

Тем самым одномерная модель учитывает упругость сосудистой стенки. При увеличении давления площадь поперечного сечения возрастает, а при снижении давления сосуд возвращается к исходному состоянию. Благодаря этому 1D-модель позволяет описывать распространение пульсовой волны, изменение давления и расхода во времени.

Для здоровых участков сосудов одномерная модель может достаточно хорошо воспроизводить основные особенности волн давления и расхода. Однако при наличии стеноза возникает дополнительная сложность. В области сужения может происходить отрыв струи, образование зон рециркуляции и неполное восстановление давления. Эти эффекты имеют выраженный трехмерный характер и не могут быть полностью описаны только усредненными по сечению величинами.

Поэтому в одномерных моделях стеноз обычно описывают не только как изменение геометрии, но и как источник дополнительных локальных потерь. Так в работе Jin и Alastruey влияние стеноза в одномерной модели учитывалось через дополнительный член, который описывал локальные потери давления на суженном участке. Одномерное моделирование проверялось путем сравнения с трехмерными расчетами. Авторы показали, что модель с такой поправкой дает результаты, близкие к результатам 3D-моделирования. При этом точность 1D-модели зависит от выраженности стеноза и режима течения. В работе отмечается, что ошибки возрастали при увеличении степени стеноза и увеличении числа Рейнольдса. Это связано с тем, что при более выраженных сужениях и более высоких скоростях возрастает роль инерционных эффектов и сложных пространственных структур потока, которые одномерная модель описывает приближенно [12].

Для рассматриваемой задачи это имеет важное значение. С одной стороны, 1D-модель является удобной и быстрой расчетной основой для описания нестационарного кровотока. С другой стороны, область стеноза требует отдельного описания локального перепада давления. Поэтому предлагается использовать аналогичную идею локального элемента, роль дополнительного члена будет играть нейросетевая модель.

Одномерные модели гемодинамики являются промежуточным подходом между простыми аналитическими оценками и полным трехмерным моделированием. Они позволяют эффективно рассчитывать распространение давления и расхода в сосуде, но для корректного описания стеноза требуют специальной модели локальных потерь.

1.4 Численное моделирование течения крови в сосуде со стенозом

Численное моделирование течения крови является более детальным подходом к исследованию гемодинамики стеноза. Его основная особенность состоит в том, что расчет позволяет получить не только итоговый показатель, но и распределение скорости, давления и других характеристик во всей рассматриваемой области течения. Основой таких расчетов являются уравнения движения вязкой жидкости, которые решаются численными методами [13], [14].

В случае несжимаемой ньютоновской жидкости течение описывается системой уравнений Навье–Стокса и уравнением неразрывности:

$$\nabla \cdot \mathbf{u} = 0, \quad (1.4.1)$$

$$\rho \left(\frac{\partial \mathbf{u}}{\partial t} + (\mathbf{u} \cdot \nabla) \mathbf{u} \right) = -\nabla p + \mu \Delta \mathbf{u} \quad (1.4.2)$$

где $\mathbf{u}$ – вектор скорости, p – давление, ρ – плотность жидкости, μ – динамическая вязкость. Первое уравнение выражает закон сохранения массы, а второе – закон сохранения импульса для вязкой жидкости.

Численное моделирование обычно включает несколько последовательных этапов. Сначала задается геометрия рассматриваемого участка сосуда. В исследовательских задачах она может быть идеализированной, например в виде прямого сосуда с параметрически заданным сужением. В задачах, ориентированных на конкретного пациента, геометрия может строиться по данным компьютерной томографии, магнитно-резонансной томографии или ангиографии. После этого задаются свойства крови, начальные и граничные условия, строится расчетная сетка и выполняется численное решение уравнений гидродинамики [14]. Такая постановка позволяет использовать CFD-моделирование для исследовательского анализа влияния отдельных параметров геометрии на течение. Например, в работе Kamangar et al. численное моделирование применялось для анализа влияния формы стеноза [6].

На практике для выполнения таких расчетов используются специализированные программные комплексы вычислительной гидродинамики, например ANSYS Fluent [15], [16]. При этом универсальные расчетные программные комплексы чаще применяются в исследовательских и инженерных задачах, чем в повседневной клинической диагностике. В клинической практике трехмерное моделирование используется в составе специализированных программных решений. Примером является HeartFlow FFRCT, где по данным коронарной компьютерной томографии строится трехмерная модель коронарного русла и рассчитывается фракционный резерв кровотока [17], [18], [19].

Отдельное направление связано с применением вычислительного моделирования при разработке и проверке сердечно-сосудистых медицинских изделий. Расчеты используются при анализе работы стентов, клапанов, насосов, сосудистых протезов и других устройств. В этом случае

моделирование позволяет заранее оценивать распределение давления, потери энергии, зоны повышенных касательных напряжений и другие характеристики, которые трудно измерить напрямую. Регуляторные документы предусматривают возможность использования вычислительного моделирования в материалах по медицинским изделиям, однако требуют описания постановки задачи, численной реализации, проверки достоверности и анализа ограничений модели [20], [21].

Несмотря на информативность, численное моделирование имеет ограничения. Результат зависит от качества восстановленной геометрии, заданных граничных условий и выбранной модели крови. Ошибки в геометрии сосуда, неточные значения расхода или давления, а также упрощенные предположения о свойствах крови могут заметно влиять на результат. В отдельных режимах приходится учитывать переходные или турбулентные эффекты [14], [15], [16].

Есть и вычислительное ограничение. Подробный трехмерный расчет занимает значительное время, при нестационарном потоке, сложной геометрии или большом числе вариантов стеноза. Поэтому трехмерное моделирование остается достаточно трудоемким процессом [14], [22], [23].

Из-за этого возникает интерес к приближенным моделям. Если уже сформирован набор CFD-расчетов, его можно использовать как данные для построения модели машинного обучения. Такая модель не заменяет исходный физический расчет полностью, но позволяет быстрее получать оценку гемодинамических показателей по входным параметрам [22], [23], [24].

Численное моделирование дает подробное описание течения крови при стенозе: можно рассматривать распределение скорости, давления и влияние геометрии сосуда. Его ограничением остается высокая вычислительная стоимость. Поэтому заранее выполненные CFD-расчеты могут использоваться как основа для приближенных моделей машинного обучения.

1.5 Методы машинного обучения для предсказания гемодинамических показателей

Методы машинного обучения позволяют оценивать связь между параметрами стеноза и перепадом давления по готовым расчетным данным. В этом случае не требуется заново решать уравнения гидродинамики для каждой новой комбинации параметров [22], [23].

Для базового сравнения используются модели разной сложности. Линейная регрессия показывает, можно ли описать целевую величину линейной комбинацией признаков. В этой задаче она служит начальным ориентиром, так как её результат легко интерпретировать. При этом ожидается, что точность линейной модели будет ограничена: перепад давления зависит от геометрии стеноза и режима течения нелинейно.

Метод ближайших соседей строит прогноз по объектам обучающей выборки, которые расположены ближе всего к рассматриваемому случаю в пространстве признаков [25]. Для расчетных данных такой подход может быть полезен, если новые точки находятся рядом с уже рассчитанными конфигурациями. Качество метода зависит от плотности обучающей выборки, числа соседей и масштабирования признаков.

Для более сложных зависимостей применяются ансамблевые методы на основе решающих деревьев. Случайный лес строит несколько деревьев и усредняет их предсказания, что повышает устойчивость модели [26]. Градиентный бустинг строит модели последовательно: каждая следующая модель исправляет ошибки предыдущих [27]. XGBoost является развитием градиентного бустинга с дополнительными механизмами регуляризации и эффективной вычислительной реализацией [28]. Такие методы подходят для табличных данных, потому что учитывают нелинейные зависимости и взаимодействия признаков.

Отдельную группу составляют нейросетевые модели. Полносвязная нейронная сеть может аппроксимировать нелинейные зависимости [29]. Это делает её подходящей для задачи предсказания перепада давления.

Высокая точность на обучающей или внутренней тестовой выборке не всегда означает хорошую работу на новых сочетаниях параметров. Это особенно важно для данных, полученных по сетке расчетных случаев. Модель может хорошо воспроизводить известные области пространства признаков, но хуже работать на новых конфигурациях. Поэтому качество нужно проверять не только на случайном разбиении исходной выборки, но и на отдельном независимом наборе данных.

Ещё одно ограничение связано с физическим смыслом результата. Обычная модель машинного обучения минимизирует численную ошибку прогноза, но сама по себе не гарантирует, что предсказанная зависимость будет согласована с ожидаемыми физическими закономерностями. Для инженерных и биомедицинских задач это особенно критично, поскольку важное значение имеет и осмысленность поведения модели при изменении входных параметров.

Методы машинного обучения являются обоснованным инструментом для этой задачи. Они позволяют построить быструю приближенную зависимость между параметрами стеноза и перепадом давления. При оценке таких моделей важно учитывать не только точность на внутренней тестовой выборке, но и интерполяционную способность, а также физическую согласованность предсказаний.

1.6 Нейросетевые модели с физически информированной функцией потерь

Нейронные сети применяются в задачах вычислительной механики и биомедицинского моделирования для аппроксимации сложных зависимостей. Полносвязная нейронная сеть способна учитывать нелинейные

взаимодействия между несколькими входными параметрами и строить приближенное отображение между входными признаками и целевой величиной [29].

К одним из направлений нейросетевых методов относятся физически информированные нейронные сети. В строгой постановке такая сеть используется для приближенного решения дифференциальной задачи: на вход подаются координаты и время, а на выходе получаются искомые физические величины, например скорость и давление. Особенность метода состоит в том, что при обучении учитываются не только данные, но и физические соотношения, описывающие процесс. Для течения жидкости такими соотношениями являются законы сохранения массы и импульса [30], [31].

Физически информированные нейросети применяются как для прямых, так и для обратных задач. В прямой задаче требуется получить решение при заданных параметрах и граничных условиях. В обратной задаче часть параметров или полей неизвестна, и их необходимо восстановить по ограниченному набору измерений. Такая постановка важна для медицинских приложений, поскольку прямое измерение давления, скорости или напряжений во всей области сосуда часто невозможно или связано с ограничениями экспериментального метода [30], [31].

В сердечно-сосудистой гемодинамике физически информированные нейронные сети применяются для восстановления характеристик кровотока по неполным или косвенным данным. Например, в работе Kissas et al. такая модель использовалась для оценки артериального давления по данным четырехмерной магнитно-резонансной томографии кровотока. В этой задаче давление восстанавливалось на основе измеряемого поля скорости и информации о движении сосудистой стенки [32].

Другой пример связан с оценкой пристеночных характеристик течения. В работе Arzani et al. физически информированные нейросети использовались для восстановления пристеночного кровотока и касательных напряжений по разреженным данным. Эти величины важны для анализа сосудистых

заболеваний, поскольку локальные напряжения на стенке связаны с развитием и прогрессированием патологических изменений сосудов [33].

Физически информированные подходы также рассматриваются для моделирования кровотока в коронарных артериях. В работе Alzhanov et al. предложена трехмерная физически информированная нейросетевая модель для расчета течения в коронарных деревьях и оценки фракционного резерва кровотока [34]. В работе Zhang et al. физически информированные нейросети рассматривались для задачи четырехмерного предсказания гемодинамики с учетом сосудистой геометрии [35]. Эти примеры показывают, что такие модели могут использоваться не только для отдельных скалярных показателей, но и для более детального описания течения.

Физическая информированность нейросетевой модели может реализовываться несколькими способами. Наиболее строгий вариант заключается во включении невязок физических уравнений в функцию ошибки. В этом случае модель получает штраф за решения, которые не удовлетворяют заданной системе уравнений. Такая постановка применяется, когда сеть восстанавливает поля физических величин в пространстве и времени [30], [31].

Физическая информация может вводиться через дополнительные ограничения в функции ошибки. Например, можно задавать ограничения на знак предсказываемой величины, выполнение балансовых соотношений или направление изменения результата при изменении входных параметров. Такая схема не всегда относится к физически информированным нейросетям в строгом смысле, но позволяет учитывать известные свойства моделируемого процесса при обучении.

Существуют способы включения физической информации через структуру самой сети. В литературе описаны подходы, где архитектура модели или функции активации выбираются с учетом свойств рассматриваемого процесса. Специальные функции активации могут использоваться для более эффективного описания решений с заранее известными особенностями, а

автоматический подбор структуры сети – для поиска архитектуры, лучше согласованной с физической задачей [36].

Для задачи предсказания перепада давления на стенозе физически информированная функция ошибки может быть построена в более простой форме. В этом случае модель не восстанавливает полное поле скорости и давления, а предсказывает интегральную величину – перепад давления на рассматриваемом участке. Физическая информация при этом может вводиться через ограничения на допустимые значения предсказания и ожидаемое направление изменения целевой величины при изменении входных параметров.

Такой вариант занимает промежуточное положение между физически информированной нейросетью в строгом смысле и обычной регрессионной моделью. Он не требует восстановления полного поля течения, но позволяет учитывать априорные сведения о предсказываемом гемодинамическом показателе. Это удобно для задач, где требуется быстро оценить функциональную характеристику стеноза по небольшому числу геометрических и гидродинамических параметров.

Нейросетевые модели с физически информированной функцией ошибки представляют собой развитие обычных моделей машинного обучения в сторону более содержательного учета предметной области. В гемодинамике такие подходы применяются для восстановления давления, оценки пристеночных характеристик кровотока, моделирования коронарного русла и предсказания функциональных показателей сосудистых поражений.

2. ПОДГОТОВКА ДАННЫХ И ПОСТРОЕНИЕ МОДЕЛЕЙ

2.1. Описание исходных данных CFD-расчетов

В работе используется готовая база данных. Численные расчеты выполнялись для трехмерного течения вязкой несжимаемой ньютоновской жидкости в прямом сосуде с локальным сужением и жесткими стенками. На входе задавался стационарный параболический профиль скорости, соответствующий выбранному числу Рейнольдса, на выходе задавалось нулевое давление, а на стенках использовалось условие прилипания.

Во всех расчетных случаях фиксированными являлись свойства жидкости и радиус здорового участка сосуда. Радиус здорового участка сосуда составлял $R_{healthy} = 0,15$ см, плотность $\rho = 1,05$ г/см³ и динамическая вязкость $\mu = 0,035$ г/(см · с).

База данных содержит 1800 наблюдений. Каждое наблюдение соответствует отдельной комбинации параметров: числа Рейнольдса, длины стеноза, степени сужения и асимметрии формы просвета. Для каждой такой комбинации задано численное значение перепада давления.

Одним из основных параметров, характеризующих режим течения, является число Рейнольдса Re . Число Рейнольдса записывается через радиус здорового участка сосуда:

$$Re = \frac{2u\rho R_{healthy}}{\mu}, \quad (2.1.1)$$

где u – средняя скорость потока, $R_{healthy}$ – радиус здорового участка сосуда, ρ – плотность жидкости, μ – динамическая вязкость.

В рассматриваемой базе данных число Рейнольдса принимало 10 значений в диапазоне от 30 до 800. В исходной таблице также представлена средняя скорость потока u . Она используется при вычислении числа

Рейнольдса и при переходе от размерного перепада давления к безразмерной форме. В дальнейшем скорость не используется как самостоятельный входной признак модели, поскольку при постоянных значениях плотности, вязкости и радиуса сосуда она непосредственно связана с числом Рейнольдса.

Длина стеноза $L_{stenosis}$ характеризует протяженность суженного участка сосуда. В исходной базе данных она принимала значения 0,375; 0,75; 1,5; 2,25; 3,0 и 4,5 см. Далее для сопоставления стенозов разной протяженности используется безразмерный параметр – отношение длины стеноза к радиусу здорового участка сосуда:

$$L_r = \frac{L_{stenosis}}{R_{healthy}}. \quad (2.1.2)$$

Параметр L_r показывает, насколько протяженным является стеноз относительно радиуса здорового участка сосуда. В рассматриваемой базе данных относительная длина стеноза принимала 6 значений: 2,5; 5; 10; 15; 20; 30. При радиусе здорового участка $R_{healthy} = 0,15$ см это соответствует указанным выше размерным длинам стеноза.

Степень стеноза S характеризует относительное уменьшение просвета сосуда. В рассматриваемой базе данных она определяется через отношение диаметра в наиболее суженной части сосуда к диаметру здорового участка:

$$S = 1 - \frac{D_{stenosis}}{D_{healthy}}. \quad (2.1.3)$$

где $D_{stenosis}$ – диаметр сосуда в области наибольшего сужения, $D_{healthy}$ – диаметр здорового участка сосуда. В исходных данных степень стеноза принимает значения от 0,0 до 0,9 с шагом 0,1.

Дополнительно в базе данных учитывается параметр асимметрии α , который описывает отклонение формы стеноза от симметричного случая. Он принимает три значения:

$\alpha = 0$, что соответствует симметричной геометрии стеноза;

$\alpha = 0,5$, что соответствует частично асимметричной геометрии;

$\alpha = 1$, что соответствует наиболее выраженной асимметрии в принятой параметризации.

Геометрическая интерпретация трех значений параметра асимметрии представлена на рисунке 2.1.1.




Рисунок 2.1.1 – Геометрия стеноза при значениях параметра асимметрии $\alpha = 0$, $\alpha = 0,5$ и $\alpha = 1$

Параметр асимметрии используется как входной признак, поскольку в расчетной базе он задает форму стеноза наряду со степенью сужения и длиной.

Физически интерпретируемой целевой переменной является размерный перепад давления, измеряемый в системе СГС в дин/см²:

$$\Delta p = p_1 - p_2, \quad (2.1.4)$$

где p_1 – давление, измеренное за 5 мм до начала сужения сосуда, p_2 – давление, измеренное через 5 мм после окончания суженного участка.

В базе данных также задан обезразмеренный перепад давления:

$$\Delta p^* = \frac{\Delta p}{\rho u^2}, \quad (2.1.5)$$

Если модель предсказывает обезразмеренное значение, то размерный перепад восстанавливается по формуле:

$$\Delta p = \Delta p^* \rho u^2. \quad (2.1.6)$$

Полная сетка параметров включает 10 значений числа Рейнольдса, 6 значений относительной длины стеноза, 10 значений степени стеноза и 3 значения параметра асимметрии. Всего получено 1800 расчетных случаев. Эти данные используются для предварительного анализа и формирования признакового пространства моделей машинного обучения.

2.2. Первичный анализ данных (EDA)

Предварительный анализ исходной таблицы включал проверку пропусков и дубликатов, оценку распределения целевой величины и выявление особенностей, которые учитывались при построении моделей.

Пропущенные значения и повторяющиеся строки не обнаружены. Расчеты выполнены по сеточному плану параметров, поэтому сочетания входных величин представлены по заданным уровням без перекоса в отдельные режимы течения.

Далее рассмотрено распределение абсолютного перепада давления ΔP , выраженного в системе СГС. Гистограмма распределения представлена на рисунке 2.2.1.




Рисунок 2.2.1 – Распределение абсолютного перепада давления

Из рисунка 2.2.1 видно, что распределение абсолютного перепада давления имеет выраженную правостороннюю асимметрию. Основная часть наблюдений сосредоточена в области малых значений, а небольшая часть расчетных случаев соответствует значительно более высоким значениям перепада давления. Поэтому на гистограмме формируется длинный правый хвост.

По описательной статистике минимальное значение абсолютного перепада давления составляет 81 дин/см², медиана – 9109 дин/см², среднее значение – около $1,7 \cdot 10^6$ дин/см², а максимальное значение достигает $5,32 \cdot 10^7$ дин/см². Различие между медианой и средним значением показывает, что целевая переменная имеет широкий динамический диапазон и чувствительна к отдельным большим значениям.

С физической точки зрения такая форма распределения является ожидаемой. При малых степенях сужения потери давления остаются относительно небольшими. При выраженных стенозах усиливаются локальные потери энергии и перепад давления может увеличиваться на порядки [5], [7].

Широкий динамический диапазон размерного перепада давления может затруднять обучение моделей. При использовании исходной шкалы ошибка на больших значениях может начинать доминировать при обучении, что снижает точность модели в области малых и средних значений целевой переменной. Поэтому было рассмотрено логарифмическое преобразование:

$$y = \ln(1 + \Delta p). \quad (2.2.1)$$

Распределение абсолютного перепада давления после логарифмирования представлено на рисунке 2.2.2




Рисунок 2.2.2 – Распределение абсолютного перепада давления в логарифмической шкале

Как видно из рисунка 2.2.2, логарифмирование существенно уменьшает разброс значений и делает распределение более компактным. Это преобразование снижает влияние редких, но очень больших значений перепада давления и делает структуру данных более удобной для последующего построения регрессионных моделей [38], [39].

Наряду с абсолютным перепадом давления в работе рассматривался обезразмеренный перепад давления:

$$\Delta p^* = \frac{\Delta p}{\rho u^2}. \quad (2.2.2)$$

Такое преобразование позволяет отнести перепад давления к характерному инерционному масштабу потока. В результате целевая величина становится менее зависимой от абсолютного уровня скорости и может рассматриваться как относительная мера гидродинамических потерь. Это согласуется с подходами гидродинамического подобия, при которых сравнение различных режимов течения проводится с использованием безразмерных величин.

Обезразмеривание уменьшает зависимость целевой величины от масштаба скорости, однако не устраняет правостороннюю асимметрию распределения.

Следующим шагом было рассмотрено логарифмирование обезразмеренного перепада давления:

$$y = \ln(1 + \Delta p^*). \quad (2.2.3)$$

Распределение этой величины представлено на рисунке 2.2.3.




Рисунок 2.2.3 – Распределение логарифмированного обезразмеренного перепада давления

После логарифмирования диапазон значений обезразмеренного перепада давления дополнительно сжимается. Распределение имеет признаки мультимодальности. Графический анализ показал, что мультимодальность распределения в основном обусловлена разделением наблюдений по значениям степени стеноза. При разных степенях сужения логарифмированный обезразмеренный перепад давления занимает разные диапазоны значений. Поэтому далее отдельно рассматривается зависимость целевой величины от степени стеноза.

Для более наглядного анализа влияния степени стеноза была построена диаграмма размаха логарифмированного обезразмеренного перепада давления от степени стеноза представленная на рисунке 2.2.4.




Рисунок 2.2.4 – Зависимость логарифмированного обезразмеренного перепада давления от степени стеноза

На рисунке 2.2.4 видно, что с ростом степени стеноза увеличиваются как медианные значения, так и верхние границы распределений. Особенно резкое смещение наблюдается при больших значениях, что подтверждает доминирующее влияние степени сужения просвета на обезразмеренный перепад давления.

Дополнительно были рассчитаны коэффициенты корреляции Пирсона и Спирмена для исходных и логарифмированных величин. Матрицы корреляции представлены на рисунках 2.2.5 и 2.2.6.




Рисунок 2.2.5 – Матрицы корреляции Пирсона и Спирмена для исходного пространства





Рисунок 2.2.6 – Матрицы корреляции Пирсона и Спирмена в log-пространстве

Корреляционный анализ показал, что степень стеноза имеет наиболее сильную связь с перепадом давления. После перехода к логарифмической шкале линейные связи усиливаются: коэффициент Пирсона для логарифмированного абсолютного перепада давления со степенью стеноза составляет около 0,81 вместо 0,39, а для логарифмированного обезразмеренного перепада давления – около 0,89 вместо 0,49. Матрица корреляции Спирмена при переходе в логарифмированное пространство не изменилась.

Следовательно, наиболее удобным представлением для дальнейшего моделирования является логарифмированный обезразмеренный перепад давления. При этом доминирующее влияние на целевую величину оказывает степень стеноза, тогда как число Рейнольдса, относительная длина стеноза и асимметрия вносят дополнительный вклад, в том числе через нелинейные взаимодействия.

2.3 Постановка задачи

2.3.1 Итоговое признаковое пространство

На основе предварительного анализа и физического смысла задачи был сформирован итоговый набор входных признаков. При выборе признаков учитывалось, что модель должна получать только те величины, которые несут самостоятельную информацию о режиме течения и геометрии стеноза. Радиус здорового участка, плотность и вязкость являются постоянными, поэтому они не несут дополнительной информации для обучения. Средняя скорость потока также не включается в итоговый набор входных признаков, поскольку при заданных постоянных параметрах она связана с числом Рейнольдса.

Итоговый набор входных признаков имеет вид:

$$x = \left(Re, \frac{L_{stenosis}}{R_{healthy}}, S, \alpha \right), \quad (2.3.1.1)$$

где Re – число Рейнольдса, $\frac{L_{stenosis}}{R_{healthy}}$ – относительная длина стеноза, S – степень стеноза, α – параметр асимметрии.

По результатам предварительного анализа в качестве целевой переменной для обучения выбран логарифмированный обезразмеренный перепад давления, рассчитанный по формулам (2.1.5) и (2.2.3). После получения прогноза выполняется обратное преобразование, а при необходимости размерный перепад восстанавливается по формуле (2.1.6). Поэтому дальнейшие ограничения на поведение модели формулируются для выбранной целевой переменной, связанной с обезразмеренным перепадом давления, а не для размерного перепада давления.

Поскольку выбранная целевая переменная является непрерывной числовой величиной, дальнейшая задача машинного обучения формулируется как задача регрессии. Необходимо построить модель, которая по набору входных параметров $x = \left(Re, \frac{L_{stenosis}}{R_{healthy}}, S, \alpha \right)$ предсказывает целевую величину $y = \ln(1 + \Delta p^*)$.

В общем виде искомое отображение можно записать следующим образом:

$$f: \left(Re, \frac{L_{stenosis}}{R_{healthy}}, S, \alpha \right) \rightarrow \ln(1 + \Delta p^*). \quad (2.3.1.2)$$

Качество моделей далее оценивается после обратного преобразования целевой переменной, то есть в исходной шкале обезразмеренного перепада давления. Это позволяет совместить удобство обучения в логарифмическом пространстве с физически осмысленной интерпретацией ошибки.

2.3.2 Расширенное признаковое пространство

Для линейной регрессии и метода ближайших соседей было сформировано расширенное признаковое пространство. В него включались производные признаки, связанные со степенью стеноза, относительной площадью просвета и взаимодействиями между входными параметрами. Для линейной регрессии такие признаки позволяют явно задать нелинейные преобразования исходных величин. Для метода ближайших соседей они изменяют пространство, в котором рассчитывается близость между расчетными случаями.

Расширенное признаковое пространство включало исходные признаки и дополнительные признаки, рассчитанные только по входным параметрам. Расширенный набор представлен в таблице 2.3.2.1.

Таблица 2.3.2.1 – Дополнительные признаки расширенного признакового пространства

Формула для формирования признака	Назначение
$(1 - (1 - S)^2)$	относительное уменьшение площади просвета
$\left(\frac{1}{(1 - S)^2 + \varepsilon}\right)$	величина, обратная относительной площади просвета
S^2	квадратичный вклад степени стеноза
S^3	кубический вклад степени стеноза
$\ln(Re + \varepsilon)$	сглаженное представление числа Рейнольдса
$\frac{L_{stenosis}}{R_{healthy}} \cdot S$	совместный учет относительной длины и степени стеноза
$\frac{L_{stenosis}}{R_{healthy}} \cdot \left(\frac{1}{(1 - S)^2 + \varepsilon}\right)$	совместный учет относительной длины и относительной площади просвета
$\log(Re + \varepsilon) \cdot S$	совместный учет режима течения и степени стеноза
$\ln(Re + \varepsilon) \cdot \frac{1}{(1 - S)^2 + \varepsilon}$	совместный учет режима течения и относительной площади просвета

$\alpha \cdot S$	совместный учет асимметрии и степени стеноза
$\alpha \cdot \frac{1}{(1 - S)^2 + \varepsilon}$	совместный учет асимметрии и относительной площади просвета

Здесь $\varepsilon = 10^{-6}$ – малое число, введенное для предотвращения деления на ноль и вычисления логарифма от нулевого значения.

Расширенное признаковое пространство использовалось только для дополнительной проверки линейной регрессии и метода ближайших соседей.

2.4 Базовые модели машинного обучения

После постановки задачи регрессии были построены базовые модели машинного обучения. Их использование необходимо для получения начального уровня качества, с которым далее сравниваются нейросетевые модели. В качестве базовых подходов были выбраны методы разной сложности: линейная регрессия, метод ближайших соседей и ансамблевые модели на основе деревьев решений.

Для основного эксперимента все модели обучались в единой постановке, определенной в разделе 2.3.1. Это означает, что для всех алгоритмов использовались одинаковые входные признаки, одинаковая целевая переменная и одинаковая процедура обратного преобразования прогноза. Это позволяет сравнивать модели между собой корректно, поскольку различия в качестве связаны с особенностями самих алгоритмов.

Дополнительно для линейной регрессии и метода ближайших соседей был проведен отдельный эксперимент с расширенным признаковым пространством, описанным в разделе 2.3.2.

Базовые модели были выбраны так, чтобы охватить несколько типов зависимости между признаками и целевой величиной. Линейная регрессия задает простое глобальное приближение. Метод ближайших соседей строит прогноз на основе локально близких наблюдений. Ансамблевые модели на

основе деревьев решений позволяют учитывать нелинейные зависимости и взаимодействия признаков.

2.4.1 Линейная регрессия

Линейная регрессия применялась как начальный ориентир для сравнения с более сложными моделями. Перед обучением линейной регрессии входные признаки стандартизировались. Это связано с тем, что признаки имеют разные численные диапазоны. Например, число Рейнольдса изменяется в значительно более широком интервале, чем степень стеноза или параметр асимметрии. Без стандартизации признаки с большим масштабом могли бы сильнее влиять на процесс подбора коэффициентов.

Линейная регрессия обладает важным преимуществом – её результаты относительно легко интерпретировать. Знак и величина коэффициентов позволяют оценить направление влияния признаков в рамках линейного приближения. Однако сама модель учитывает только линейный вклад тех признаков, которые были переданы ей на вход. Поэтому при использовании только исходных четырех параметров её возможности ограничены формой выбранного признакового пространства.

В связи с этим для линейной регрессии дополнительно рассматривался вариант с расширенным набором признаков. В него включались не только исходные параметры, но и производные признаки, отражающие изменение площади просвета, степени стеноза и взаимодействия между параметрами. Введение таких признаков позволяет добавить в линейную модель нелинейные преобразования исходных величин, сохраняя при этом простую и интерпретируемую форму самой регрессии.

Линейная регрессия использовалась в двух вариантах: на исходном признаковом пространстве и на расширенном признаковом пространстве. Первый вариант служит простой базовой точкой сравнения, а второй

показывает, как меняется качество линейной модели при добавлении признаков.

2.4.2 Метод ближайших соседей

Метод ближайших соседей относится к непараметрическим методам машинного обучения. В отличие от линейной регрессии, он не задает заранее конкретный вид зависимости между признаками и целевой переменной. Прогноз для нового наблюдения строится на основе объектов обучающей выборки, наиболее близких к нему в пространстве признаков [38].

Поскольку входные признаки имеют разные численные диапазоны, перед применением метода ближайших соседей так же выполнялось масштабирование.

Для выбора параметров метода был выполнен сеточный поиск с использованием кросс-валидации на обучающей выборке. Рассматривались различные способы масштабирования признаков, разные значения числа соседей, варианты взвешивания соседей, а также несколько метрик расстояния. Подбор выполнялся по средней абсолютной ошибке.

В результате подбора была выбрана следующая конфигурация метода ближайших соседей: число соседей $k = 7$, взвешивание по расстоянию, метрика Минковского с параметром $p = 3$. Для масштабирования признаков использовалось квантильное преобразование. Такая конфигурация означает, что прогноз формировался по семи ближайшим объектам обучающей выборки, причем более близкие объекты получали больший вес при расчете итогового значения.

Метрика Минковского в общем виде записывается как

$$d(x_i, x_j) = \left(\sum_{m=1}^M |x_{im} - x_{jm}|^p \right)^{1/p}, \quad (2.4.2.1)$$

где x_i и x_j – два объекта в пространстве признаков, M – число признаков, p – параметр метрики. При $p = 1$ эта метрика соответствует манхэттенскому расстоянию, при $p = 2$ – евклидову расстоянию. В выбранной конфигурации использовалось значение $p = 3$.

Метод ближайших соседей полезен для рассматриваемой задачи, поскольку он позволяет использовать локальную структуру расчетных данных. Если два случая близки по числу Рейнольдса, относительной длине стеноза, степени стеноза и асимметрии, то ожидается, что соответствующие значения перепада давления также будут близки. Однако данный метод зависит от плотности обучающей выборки и от выбранного признакового пространства. Если вблизи нового наблюдения нет достаточно близких расчетных случаев, точность прогноза может снижаться.

Учитывая чувствительность метода ближайших соседей к признаковому пространству, далее дополнительно рассматривается его применение на расширенном наборе признаков.

Метод ближайших соседей использовался как локальная базовая модель регрессии. В отличие от линейной регрессии, он не требует задания явной аналитической формы зависимости, но требует аккуратного выбора масштабирующего преобразования, метрики расстояния, числа соседей, схемы взвешивания и набора признаков.

2.4.3 Ансамблевые модели на основе деревьев решений

Для учета нелинейных зависимостей в работе также использовались ансамблевые модели на основе деревьев решений. К ним относятся случайный лес, градиентный бустинг и XGBoost. Эти методы позволяют описывать сложные зависимости между входными параметрами и целевой величиной без явного задания аналитической формулы.

Для случайного леса подбирались следующие гиперпараметры: число деревьев, максимальная глубина дерева, минимальное число объектов в листе

и число признаков, доступных при поиске разбиения. В выбранной конфигурации использовались 600 деревьев, максимальная глубина 15, минимальный размер листа 1 и использование 80 % признаков при разбиениях.

Для градиентного бустинга подбирались число деревьев, глубина дерева, скорость обучения, минимальное число объектов в листе и доля объектов, используемая при построении очередного дерева. В выбранной конфигурации использовались деревья глубины 3, 800 деревьев, скорость обучения 0,1, минимальное число объектов в листе 5 и доля подвыборки 0,8. В качестве функции потерь применялась квадратичная ошибка.

Для XGBoost подбирались скорость обучения, число деревьев, глубина деревьев, минимальный вес дочернего узла, доля объектов и признаков, используемых при построении деревьев, а также коэффициенты регуляризации. В выбранной конфигурации использовались глубина деревьев 3, 2000 деревьев, скорость обучения 0,1, минимальный вес дочернего узла 8, коэффициент L2-регуляризации = 1 и отсутствие дополнительной L1 регуляризации.

Подбор гиперпараметров ансамблевых моделей выполнялся с помощью сеточного поиска, который выполнялся по средней абсолютной ошибке. В программной реализации использовался критерий `neg_mean_absolute_error`, что соответствует минимизации MAE. Внутри обучающей выборки использовалась групповая перекрестная проверка с пятью разбиениями. В качестве групп задавались сочетания степени стеноза и относительной длины стеноза. Такая схема уменьшает риск завышенной оценки качества при подборе параметров, поскольку близкие по геометрии расчетные случаи не разделяются произвольно между обучающими и проверочными частями.

Ансамблевые модели были включены в работу потому, что перепад давления при стенозе зависит от входных параметров нелинейно. Кроме того, признаки могут влиять на целевую величину не только по отдельности, но и через совместные взаимодействия. Модели на основе деревьев решений

позволяют учитывать такие зависимости без введения дополнительных вручную заданных признаков.

2.5 Нейросетевые модели

Полносвязная нейронная сеть позволяет аппроксимировать нелинейную зависимость без явного задания аналитической формулы и учитывать совместное влияние входных признаков [29].

В работе рассматривались две нейросетевые модели. Первая модель представляет собой обычную полносвязную нейронную сеть прямого распространения, обучаемую только по данным. Вторая модель имеет ту же архитектуру, но её функция ошибки дополнена физически информированной частью. Эта часть вводится для того, чтобы ограничить возможное поведение модели и уменьшить вероятность физически неосмысленных предсказаний.

Обе нейросетевые модели строились в одинаковых условиях: использовалась одна и та же архитектура, одинаковая подготовка входных данных, одинаковый алгоритм оптимизации и одинаковое начальное состояние параметров. Это необходимо для корректного сравнения, поскольку различия между моделями должны быть связаны именно с наличием или отсутствием физически информированной части в функции ошибки, а не с разной структурой сети или разными условиями обучения.

В строгом смысле вторая модель не является классической физически информированной нейронной сетью, поскольку в функцию ошибки не включаются невязки уравнений Навье-Стокса. Физическая информация задается в более простой форме – через ограничения на знак предсказания и направление изменения выхода модели по входным параметрам [30].

2.5.1 Архитектура нейронной сети

Для обеих нейросетевых моделей использовалась одинаковая полносвязная архитектура прямого распространения. В такой сети информация последовательно проходит от входного слоя к выходному через скрытые слои; обратные связи между слоями отсутствуют. Подобная структура соответствует классической схеме многослойного персептрона [29], [40]. Архитектура сети представлена на рисунке 2.5.1.1.




Рисунок 2.5.1.1 – архитектура нейронной сети

Сеть включала следующие элементы:

- входной линейный слой с четырьмя входами и шестнадцатью выходами;
- первую нелинейную функцию активации;
- второй линейный слой с шестнадцатью входами и шестнадцатью выходами;
- вторую нелинейную функцию активации;
- выходной линейный слой с одним выходным значением.

В качестве функции активации в скрытых слоях использовался гиперболический тангенс. Его выбор связан с двумя причинами. Во-первых, эта функция является гладкой и дифференцируемой, что важно для

устойчивого обучения сети градиентными методами. Во-вторых, в модели с физически информированной функцией ошибки требуется вычислять производные выхода сети по входным признакам. Поэтому использование гладкой функции активации делает такие производные более корректными и устойчивыми [29], [41].

Архитектура была выбрана компактной. Это связано с размером исходного набора данных и характером задачи: слишком большая сеть могла бы избыточно подстраиваться под обучающие данные, тогда как слишком простая сеть могла бы не уловить нелинейную зависимость. Два скрытых слоя по 16 нейронов являются компромиссным вариантом.

Для обучения сети использовался метод обратного распространения ошибки. На каждом шаге сначала вычислялось предсказание модели, затем значение функции ошибки, после чего с помощью градиентов обновлялись параметры сети. Обновление параметров выполнялось с использованием оптимизатора Adam при скорости обучения 10^{-4} . Данное значение скорости обучения было выбрано для обеспечения устойчивой оптимизации: при слишком большом шаге функция ошибки может изменяться неустойчиво, а при слишком малом обучение становится чрезмерно медленным. Обучение проводилось в течение 30000 эпох. Такое число эпох было выбрано с учетом необходимости обеспечить сходимость нейросетевых моделей при сохранении одинаковых условий сравнения. Это является стандартным подходом при обучении многослойных нейронных сетей [40], а использование адаптивного оптимизатора Adam широко применяется при обучении нейросетевых моделей [42].

2.5.2 Полносвязная нейронная сеть

Обычная полносвязная нейронная сеть использовалась как нейросетевой базовый вариант. В отличие от модели с физически информированной функцией ошибки, она обучалась только по данным и не содержала

дополнительных ограничений на форму зависимости между входом и выходом.

Функция ошибки обычной сети задавалась как среднеквадратичная ошибка:

$$L_{data} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2, \quad (2.5.2.1)$$

где N – число объектов обучающей выборки, y_i – истинное значение целевой переменной, $\hat{y}_i$ – предсказанное значение.

Среднеквадратичная ошибка выбрана потому, что она является гладкой и дифференцируемой функцией. Это позволяет применять градиентные методы оптимизации. Кроме того, такая ошибка сильнее штрафует крупные отклонения, что важно для задачи, где большие ошибки на отдельных режимах могут существенно ухудшать физическую интерпретацию результата.

Итоговая функция ошибки обычной сети имела вид

$$L_{FFNN} = L_{data}. \quad (2.5.2.2)$$

Такая модель необходима для сравнения с физически информированным вариантом. Если обе сети имеют одинаковую архитектуру и обучаются в одинаковых условиях, то различия в их поведении можно связывать с добавлением физической составляющей в функцию ошибки.

2.5.3 Физически информированная нейронная сеть

Нейросетевая модель с физически информированной функцией ошибки строилась на основе той же полносвязной архитектуры, что и обычная сеть.

Общую функцию ошибки можно представить в виде

$$L_{total} = L_{data} + \omega_{phys}L_{phys}, \quad (2.5.3.1)$$

где L_{data} – ошибка предсказания по обучающим данным, L_{phys} – дополнительная составляющая, связанная с физическими ограничениями, ω_{phys} – коэффициент, определяющий вклад физического штрафа.

Физически информированная часть включала два типа ограничений. Первое ограничение связано с монотонностью зависимости. В пределах рассматриваемой расчетной области ожидается, что увеличение степени стеноза, относительной длины стеноза и параметра асимметрии не должно приводить к уменьшению потерь давления. Для числа Рейнольдса в принятой постановке также задается ожидаемое направление изменения, соответствующее используемому варианту целевой переменной и диапазону данных. Для размерного перепада давления при увеличении скорости и числа Рейнольдса ожидается рост потерь давления. Однако нейросеть обучается на обезразмеренной величине Δp^* , нормированной на динамический масштаб ρu^2 . Поэтому ограничение по числу Рейнольдса задается не для размерного перепада давления, а для выбранной обезразмеренной целевой величины. Предварительный анализ данных показал, что в рассматриваемом диапазоне для Δp^* наблюдается убывающее направление зависимости от Re , что и учитывается в физическом штрафе.

В математическом виде принятые физические ограничения можно записать следующим образом:

$$\frac{\partial \Delta p^*}{\partial Re} \leq 0, \frac{\partial \Delta p^*}{\partial \frac{L_{stenosis}}{R_{healthy}}} \geq 0, \frac{\partial \Delta p^*}{\partial S} \geq 0, \frac{\partial \Delta p^*}{\partial \alpha} \geq 0. \quad (2.5.3.2)$$

В программной реализации контроль монотонности выполнялся через производные выхода сети по входным признакам. Если знак производной не соответствовал заданному физическому ограничению, к функции ошибки добавлялся штраф.

Производные вычислялись с помощью автоматического дифференцирования. В этом случае они находятся не по конечным разностям, а через вычислительный граф модели. После прямого прохода сеть формирует предсказание, затем программная среда применяет правило цепочки и вычисляет производные выхода по входным признакам. Это позволяет включать производные непосредственно в функцию ошибки при обучении модели с физическими ограничениями [41].

Второе ограничение связано с неотрицательностью перепада давления:

$$\Delta p^* \geq 0. \quad (2.5.3.3)$$

В рассматриваемой постановке перепад давления на стенозе связан с потерями энергии потока. Поэтому модель не должна предсказывать отрицательные значения этой величины. Если предсказание приводило к отрицательному перепаду давления, в функцию ошибки добавлялся дополнительный штраф.

Физически мотивированную часть можно представить как сумму двух составляющих:

$$L_{phys} = L_{mono} + L_{nonneg}, \quad (2.5.3.4)$$

где L_{mono} – штраф за нарушение ожидаемого направления изменения предсказания, L_{nonneg} – штраф за отрицательные значения предсказанного перепада давления.

Весовой коэффициент ω_{phys} играет важную роль. Если он слишком мал, физическая часть почти не влияет на обучение, и модель фактически становится обычной нейронной сетью. Если он слишком велик, физические ограничения начинают подавлять согласование с данными, и модель может хуже воспроизводить результаты численных расчетов. Поэтому вес физической части должен обеспечивать баланс между точностью

аппроксимации и физической согласованностью предсказаний. Поэтому весовой коэффициент подбирался эмпирически в ходе обучения модели. При подборе учитывалось соотношение между ошибкой по данным и физически информированным штрафом. В данной реализации $\omega_{phys} = 0,5$.

В результате нейросетевая модель с физически информированной функцией ошибки отличается от обычной сети тем, что при обучении учитывает не только численное расхождение с расчетными данными, но и дополнительные требования к физически ожидаемому поведению предсказания.

3. ОЦЕНКА КАЧЕСТВА И ИНТЕРПОЛЯЦИОННОЙ СПОСОБНОСТИ МОДЕЛЕЙ

В данной главе проводится оценка качества моделей, описанных в главе 2. Сравнение выполняется на двух уровнях: на внутренней тестовой выборке, полученной при разбиении исходного набора данных, и на независимом наборе данных, который не использовался при обучении и подборе параметров моделей.

Такой порядок анализа необходим, поскольку высокая точность на внутренней тестовой выборке не всегда означает хорошую переносимость модели на промежуточные значения степени стеноза, отсутствующие в обучающей сетке. Поэтому отдельно рассматриваются качество аппроксимации внутри исходной базы данных и интерполяционная способность моделей на независимом наборе.

Оценка выполнялась после обратного преобразования целевой переменной, то есть в шкале обезразмеренного перепада давления.

3.1 Схема оценки качества моделей

Перед построением моделей исходный набор данных был разделен на обучающую и тестовую части в отношении 80/20. Обучающая часть использовалась для обучения моделей и подбора их параметров, а тестовая часть – только для итоговой проверки качества. При разбиении применялась стратификация по степени стеноза, поскольку этот параметр оказывает существенное влияние на величину перепада давления. Такой подход позволил сохранить близкое распределение степени стеноза в обучающей и тестовой выборках.

Качество регрессионных моделей оценивалось с помощью нескольких метрик. Использование только одного показателя недостаточно, так как разные метрики отражают разные стороны ошибки: средний уровень отклонения,

чувствительность к крупным ошибкам, относительную ошибку и долю объясненной изменчивости данных [38], [39].

Средняя абсолютная ошибка MAE вычислялась по формуле

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (3.1.1)$$

где n – число наблюдений, y_i – истинное значение целевой величины, $\hat{y}_i$ – предсказанное значение.

MAE показывает среднюю величину абсолютного отклонения прогноза от истинного значения. Эта метрика удобна для интерпретации, поскольку выражается в тех же единицах, что и оцениваемая величина.

Для учета крупных ошибок дополнительно рассчитывалась среднеквадратичная ошибка RMSE:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (3.1.2)$$

В отличие от MAE, метрика RMSE сильнее штрафует большие отклонения. Поэтому она позволяет оценить, насколько модель чувствительна к отдельным крупным ошибкам.

Также использовался коэффициент детерминации R^2 :

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (3.1.3)$$

где $\bar{y}$ – среднее значение истинной целевой величины.

Коэффициент R^2 показывает, какая доля изменчивости целевой переменной объясняется моделью. Значение, близкое к единице, соответствует

хорошему воспроизведению общей структуры данных. Однако этот показатель не следует рассматривать отдельно от абсолютных ошибок, поскольку высокое значение R^2 не всегда означает малые отклонения в отдельных расчетных случаях.

Для оценки относительной ошибки использовалась метрика WAPE:

$$WAPE = \frac{MAE}{\frac{1}{n} \sum_{i=1}^n |y_i|} * 100\%. \quad (3.1.4)$$

WAPE показывает суммарную абсолютную ошибку, нормированную на сумму истинных значений. Эта метрика удобна для сравнения моделей, поскольку выражает ошибку в процентах от общего масштаба целевой величины.

Все метрики качества в главах 3.2–3.4 рассчитывались после обратного логарифмического преобразования целевой переменной. То есть сравнение выполнялось не в логарифмической шкале, а в шкале обезразмеренного перепада давления Δp^* .

3.2. Результаты базовых моделей на тестовой выборке

Сначала были оценены базовые модели машинного обучения: линейная регрессия, метод ближайших соседей, градиентный бустинг, случайный лес и XGBoost.

Дополнительно для линейной регрессии и к-ближайших соседей рассматривался вариант с расширением признакового пространства. В этом случае к исходным параметрам добавлялись производные признаки, отражающие нелинейный характер задачи: квадратичные и кубические степени стеноза, логарифм числа Рейнольдса, отношение площадей, а также произведения параметров между собой. Это было использовано для проверки того, может ли явное добавление физически осмысленных нелинейных

комбинаций улучшить качество простых моделей. Результаты представлены в таблице 3.2.1.

Таблица 3.2.1 – Качество базовых моделей на тестовой выборке в шкале обезразмеренного перепада давления Δp^*

Модель	R^2	MAE	RMSE	WAPE, %
Линейная модель	0,1630	717	2427	81,91
Метод ближайших соседей	0,5748	455,18	1452,13	57,64
Градиентный бустинг	0,9981	28	114	3,15
XGBoost	0,9989	24	89	2,69
Случайный лес	0,9963	35	162	3,99
Линейная модель с расширенным признаковым пространством	0,9163	139	768	15,92
Метод ближайших соседей с расширенным признаковым пространством	0,9503	73	591	8,31

Для визуального сравнения качества базовых моделей в четырехмерном признаковом пространстве на рисунке 3.2.1 показаны графики зависимости предсказанных значений перепада давления от истинных значений на тестовой выборке.




Рисунок 3.2.1 – Сравнение истинных и предсказанных значений обезразмеренного перепада давления для базовых моделей машинного обучения на тестовой выборке в четырехмерном признаковом пространстве

Далее на рисунке 3.2.2 представлены сравнения для линейной регрессии и к-ближайших соседей на исходном признаковом пространстве и расширенном




Рисунок 3.2.2 – Сравнение истинных и предсказанных значений обезразмеренного перепада давления для простых моделей машинного обучения на тестовой выборке в четырехмерном и расширенном пространстве

Наилучшие результаты на внутренней тестовой выборке показали ансамблевые модели на основе деревьев решений. Градиентный бустинг и XGBoost дали близкие значения метрик: R^2 оказался практически равным единице, а абсолютные ошибки были минимальными среди рассмотренных базовых моделей. Случайный лес также показал высокое качество, но уступил бустинговым моделям по MAE, RMSE и WAPE.

Результаты показывают, что исходные признаки недостаточны для точного описания перепада давления простыми моделями. Линейная модель и метод ближайших соседей существенно улучшаются после добавления производных признаков. При этом ансамблевые модели на основе деревьев решений показывают наиболее высокое качество даже на исходном наборе

признаков, поскольку способны автоматически учитывать нелинейные зависимости и взаимодействия между параметрами.

3.3. Результаты нейросетевых моделей на тестовой выборке

Далее были оценены две нейросетевые модели. Результаты проверки на тестовой выборке представлены в таблице 3.3.1

Таблица 3.3.1 – Качество нейросетевых моделей на тестовой выборке

Модель	R^2	MAE	RMSE	WAPE, %
Нейронная сеть с физически информированной функцией ошибки	0,998277	30,1004	110,1369	3,44
Обычная нейронная сеть	0,997622	33,4489	129,3789	3,82

Также сравнение моделей представлено на рисунке 3.3.1:




Рисунок 3.3.1 – Сравнение расчетных и предсказанных значений перепада давления для обычной нейронной сети и нейросетевой модели с физически информированной функцией ошибки

Обе нейросетевые модели показали высокое качество предсказания. Значения коэффициента детерминации превышают 0,997, что указывает на хорошее воспроизведение общей изменчивости целевой переменной.

В целом результаты на тестовой выборке показывают, что добавление физически информированной части в функцию ошибки немного улучшило основные абсолютные метрики и коэффициент детерминации. Однако различия между двумя нейросетевыми моделями на внутреннем тесте невелики, поскольку исходная CFD-база имеет регулярную структуру, не содержит пропущенных значений и относится к одной идеализированной расчетной постановке, поэтому обычная полносвязная нейронная сеть уже хорошо аппроксимирует зависимость между входными параметрами и целевой величиной.

3.4. Проверка моделей на независимом наборе данных

Для дополнительной оценки качества была проведена проверка на независимом наборе данных. Независимый набор использовался для дополнительной интерполяционной проверки внутри той же расчетной постановки.

Независимый набор данных был сформирован по той же логике, что и основная расчетная база: он представлял собой полный набор комбинаций заданных значений числа Рейнольдса, относительной длины стеноза, степени стеноза и параметра асимметрии. Главное отличие состояло в выборе степеней стеноза: в основной базе значения степени сужения задавались с шагом 0,1, то есть в процентах были кратны 10 %, тогда как в независимом наборе использовались значения 0,33 и 0,66. Эти значения не совпадают с узлами исходной сетки параметров, поэтому такая проверка позволяет оценить способность моделей выполнять интерполяцию по степени стеноза, а не только воспроизводить значения для уже представленных уровней сужения.

Общее число наблюдений составило 240. Результаты базовых моделей на независимом наборе представлены в таблице 3.4.1

Таблица 3.4.1 – Качество моделей на независимом наборе данных

Модель	R^2	MAE	RMSE	WAPE, %
PINN	0,9980	1,3456	2,7704	2,94
FFNN	0,9979	1,4645	2,8254	3,20
Метод ближайших соседей, расшир.	0,9393	6,3209	15,2196	13,8165
Линейная регрессия, расшир.	0,9224	7,2629	17,2094	15,8753
Метод ближайших соседей	0,8862	9,1723	20,8479	20,0490
Градиентный бустинг	0,7169	21,8908	32,8777	47,8495
Случайный лес	0,7069	22,4193	33,4532	49,0046
XGBoost	0,5866	22,1931	39,7327	48,5102
Линейная регрессия	-0,3947	46,8777	72,9767	102,4665

Из таблицы 3.4.1 видно, что на независимом тестовом наборе наилучшие результаты показали нейросетевые модели. Модель PINN имеет максимальное значение коэффициента детерминации $R^2 = 0,9980$, а также минимальные значения ошибок: MAE = 1,3456, RMSE = 2,7704 и WAPE = 2,94 %. Очень близкий результат получен для обычной полносвязной нейронной сети FFNN: $R^2 = 0,9979$, MAE = 1,4645, RMSE = 2,8254 и WAPE = 3,20 %. Это показывает, что обе нейросетевые модели хорошо интерполируют зависимость между параметрами стеноза и перепадом давления на независимых данных.

Среди классических моделей машинного обучения лучший результат показал метод ближайших соседей с расширенным признаковым пространством. Для него значение R^2 составило 0,9393, а WAPE – 13,8165 %. Линейная регрессия с расширенным признаковым пространством также показала высокое качество: $R^2 = 0,9224$, WAPE = 15,8753 %. Добавление производных признаков существенно улучшает качество простых моделей, так как позволяет частично учесть нелинейный характер зависимости.

Метод ближайших соседей без расширения признакового пространства оказался достаточно устойчивым на независимом наборе: $R^2 = 0,8862$, WARE = 20,0490 %. Однако его качество ниже, чем у варианта с добавлением признаков. Это показывает, что для KNN важен не только выбор числа соседей и метрики расстояния, но и само признаковое пространство, в котором сравниваются объекты.

Градиентный бустинг, случайный лес и XGBoost показали более низкое качество по сравнению с нейросетевыми моделями и моделями с расширенным набором признаков. Для градиентного бустинга значение R^2 составило 0,7169, для случайного леса – 0,7069, для XGBoost – 0,5866. При этом значения WARE для этих моделей находятся примерно на уровне 48–49 %, что указывает на заметное ухудшение интерполяционной способности на независимых данных.

Снижение качества ансамблевых моделей на независимом наборе может быть связано с особенностями их построения. Модели на основе деревьев решений разбивают признаковое пространство на отдельные области и формируют прогноз на основе разбиений, полученных по обучающим данным. Поэтому при переходе к значениям параметров, отсутствующим в обучающей сетке, такие модели могут выполнять менее гладкую интерполяцию, чем нейросетевые модели.

Независимая проверка показала, что наилучшей интерполяционной способностью обладают нейросетевые модели. Среди классических моделей наиболее устойчивыми оказались метод ближайших соседей и линейная регрессия при использовании расширенного признакового пространства. Полученные результаты также подтверждают, что высокая точность модели на внутренней тестовой выборке не всегда гарантирует хорошее качество на независимых данных, поэтому отдельная проверка на внешнем наборе является необходимым этапом сравнения моделей.

4. ИНТЕГРАЦИЯ НЕЙРОННОЙ СЕТИ В ОДНОМЕРНУЮ МОДЕЛЬ ГЕМОДИНАМИКИ

4.1. Алгоритм интеграции PINN в одномерный расчет

Цель интеграции нейросетевого модуля состоит в том, чтобы включить предсказание перепада давления на стенозе в одномерный расчет гемодинамики. В предыдущих главах была построена модель, которая по параметрам течения и геометрии стеноза предсказывает перепад давления. На вход модели подаются число Рейнольдса, относительная длина стеноза, степень стеноза и параметр асимметрии.

В стандартной одномерной модели стеноз представлен как участок сосуда с уменьшенным радиусом. Такой способ позволяет учесть изменение площади поперечного сечения и связанное с этим изменение скорости потока. Однако он не описывает в явном виде трехмерные эффекты, возникающие в области сужения: локальное ускорение потока, отрыв струи, рециркуляционные зоны и дополнительные потери давления после стеноза. Поэтому одного только задания уменьшенного радиуса может быть недостаточно для корректного описания гидродинамического сопротивления стенозированного участка.

В данной работе стеноз задается иначе. Поскольку обученная нейросетевая модель предсказывает не распределение скорости и давления внутри стеноза, а интегральную величину – стеноз рассматривается как сосредоточенный интерфейсный элемент, расположенный между двумя одномерными сосудами.

В обычном узле без локального сопротивления выполняется условие сохранения расхода и условие согласования давления. Для двух соединяемых сосудов это можно записать как

$$Q_1 = Q_2, \quad (4.1.1)$$

В узле со стенозом условие сохранения расхода сохраняется, так как масса крови не должна теряться в области соединения (4.1.1).

Однако давление после стеноза должно быть меньше давления до стеноза на величину локальной потери. Поэтому вместо равенства давлений используется условие:

$$p_1 = p_2 + \Delta p_{PINN}, \quad (4.1.2)$$

где Δp_{PINN} – перепад давления, рассчитанный нейронной сетью.

В вычислительной реализации используется не только статическое давление, но и динамический член. Поэтому условие сопряжения записывается через полное давление:

$$\left(p_1 + \frac{\rho U_1^2}{2}\right) - \left(p_2 + \frac{\rho U_2^2}{2}\right) = \Delta p_{PINN}. \quad (4.1.3)$$

Физический смысл этого условия состоит в том, что разность полных давлений между входом и выходом стеноза равна дополнительной потере энергии, вызванной локальным сужением. Нейросеть в этом случае играет роль модели локального гидравлического сопротивления.

Обучающие CFD-расчеты, использованные для построения PINN-модуля, были выполнены в стационарной постановке. При этом одномерная модель является нестационарной: расход, скорость, площадь поперечного сечения и давление изменяются во времени. На каждом временном шаге PINN-модель получает текущий режим течения из одномерной модели и возвращает соответствующий перепад давления на стенозе. Нейросеть не описывает всю историю течения и не учитывает возможную фазовую задержку, а используется как локальная модель мгновенной потери давления. Что близко к использованию эмпирических моделей стеноза в одномерной гемодинамике:

локальная потеря также вычисляется на каждом временном шаге по текущему расходу или скорости.

В вычислительной схеме стеноз задается как специальное граничное условие сопряжения между двумя одномерными сосудами. Алгоритм расчета очередного шага по времени Δt , перехода от n к $n+1$, представлен на рисунке 4.1 и состоит из этапов:

1. Расчет внутренних точек: сначала стандартной одномерной схемой на основе потоковых функций F_A и F_u независимо обновляются внутренние узлы всех сосудов.
2. Характеристическое замыкание: для граничных сечений на стыке со стенозом из характеристических соотношений выводятся линейные связи скоростей и площадей: $u_1 = \alpha_1 S_1 + \beta_1$ и $u_2 = \alpha_2 S_2 + \beta_2$. Коэффициенты α и β вычисляются по уже известным значениям во внутренних узлах сосудов. Подробный вывод таких коэффициентов из конечно-разностной аппроксимации характеристической формы одномерных уравнений кровотока приведён в работе S. Simakov, T. Gamilov, Y. N. Soe [43].
3. Итерационный расчет узла (вызов PINN): площади S_1, S_2 неизвестны, запускается внутренний итерационный цикл. На каждой итерации по текущему расходу Q вычисляется число Re , которое вместе с геометрией стеноза подается на вход нейросети. Возвращаемый перепад Δp_{PINN} подставляется в уравнение баланса полного давления.
4. Обновление граничных значений: после сходимости итераций найденные площади и пересчитанные по характеристикам скорости фиксируются на $n + 1$, и система переходит к следующему шагу по времени.




Рисунок 4.1.1 – Алгоритм расчета одного временного шага одномерной модели с учетом нейросетевого модуля

4.2. Формирование входа PINN-модуля в одномерном расчете

В предыдущих главах были описаны входные параметры нейросетевой модели: число Рейнольдса, относительная длина стеноза, степень стеноза и параметр асимметрии. При интеграции модели в одномерный расчет эти параметры используются в том же виде, однако режим течения теперь определяется не из заранее подготовленной таблицы, а из текущего состояния 1D-модели.

На каждом временном шаге одномерная модель рассчитывает значения площади поперечного сечения, скорости, расхода и давления на концах сосудистых сегментов. Эти величины используются для определения текущего режима течения в узле стеноза. Геометрические параметры стеноза при этом задаются перед началом расчета и остаются фиксированными для выбранного расчетного случая.

Далее будут рассмотрены два варианта интеграции. Основное отличие между реализованными вариантами интеграции связано с тем, как именно вычисляется число Рейнольдса.

В первом варианте режим течения для PINN-модуля задается через расход, полученный из текущего состояния одномерной модели. При этом скорость, используемая для вычисления числа Рейнольдса, определяется не через текущую площадь деформируемого сосуда, а через фиксированную площадь нормального сечения A_{ref} :

$$A_{\text{ref}} = \pi R_{\text{ref}}^2, \quad (4.2.1)$$

$$U_Q = \frac{|Q|}{A_{\text{ref}}} = \frac{|Q|}{\pi R_{\text{ref}}^2}. \quad (4.2.2)$$

Тогда число Рейнольдса вычисляется как:

$$Re_Q = \frac{2\rho U_Q R_{\text{ref}}}{\mu}. \quad (4.2.3)$$

Такой вариант соответствует способу формирования входных данных, использованному при обучении нейросетевой модели: расход переводится в характерную скорость через фиксированную площадь здорового участка сосуда. Поэтому влияние упругого изменения площади в 1D-модели не попадает напрямую во вход PINN, а текущий режим течения задается только через расход.

Во втором варианте используется локальная скорость, рассчитанная непосредственно в граничном узле 1D-модели. В этом случае скорость уже зависит от текущей площади поперечного сечения, которая изменяется во времени из-за упругости сосудистой стенки. Число Рейнольдса определяется как:

$$Re_U = \frac{2\rho U_{\text{interface}} R_{\text{ref}}}{\mu}. \quad (4.2.4)$$

Различие между двумя вариантами состоит в способе учета площади. В варианте по Q используется фиксированная площадь, согласованная с обучением PINN, а в варианте по U скорость берется из нестационарного одномерного решения и зависит от текущей деформации сосуда.

Для повышения численной устойчивости модуля расхода или скорости использовалось сглаживание. Вместо модуля $|Q|$ используется выражение:

$$|Q|_\varepsilon = \sqrt{Q^2 + \varepsilon_Q^2}. \quad (4.2.5)$$

Аналогично для скорости:

$$|U|_{\varepsilon} = \sqrt{U^2 + \varepsilon_U^2}. \quad (4.2.6)$$

Такое сглаживание устраняет разрыв производной в окрестности нуля. Это важно при итерационном решении нелинейной системы, поскольку в методе Ньютона используются производные по неизвестным.

Выход нейросети задается в безразмерной форме. Для использования в 1D-модели его нужно перевести в размерный перепад давления. Нейросеть возвращает безразмерный перепад давления Δp^* , размерная величина восстанавливается через динамический масштаб давления:

$$\Delta p_{\text{PINN}} = \Delta p^* \rho U^2. \quad (4.2.7)$$

Далее величина переводится в мм рт. ст. и подставляется в условие сопряжения.

4.3. Численное решение узлового условия

Узел со стенозом отличается от обычного узла сопряжения тем, что в условии баланса давления появляется дополнительная величина Δp_{PINN} . Она вычисляется нейросетевой моделью и зависит от текущего режима течения. В результате узловое условие становится нелинейным.

Для решения этого условия в программе используется итерационный метод Ньютона. На каждой итерации формируется система невязок, включающая два основных условия: сохранение расхода и баланс полного давления с учетом потери на стенозе. В общем виде её можно записать как

$$\mathbf{R}(\mathbf{A}) = \mathbf{0} \quad (4.3.1)$$

где $\mathbf{A}$ – вектор неизвестных граничных площадей, а $\mathbf{R}$ – вектор невязок узловых условий.

На каждой итерации метода Ньютона вычисляется поправка к текущему приближению. Однако для узла со стенозом полный шаг Ньютона может быть неустойчивым. Это связано с тем, что перепад давления на стенозе является нелинейной функцией расхода или скорости, а также с тем, что площадь поперечного сечения должна оставаться положительной. Поэтому в программе используется не полный, а демпфированный шаг Ньютона:

$$\mathbf{A}^{k+1} = \mathbf{A}^k - \lambda_k \Delta \mathbf{A}^k, \quad 0 < \lambda_k \leq 1 \quad (4.3.2)$$

Параметр λ_k определяет длину шага. Сначала проверяется полный шаг $\lambda_k = 1$. Если после него площадь становится неположительной или норма невязки не уменьшается, шаг последовательно уменьшается. Что соответствует демпфированному варианту метода Ньютона: если полный шаг ухудшает сходимость, величина обновления уменьшается. Это повышает устойчивость итерационного решения нелинейной системы. [37], [44], [45].

В реализации используется простое уменьшение шага: при неудачной попытке параметр λ_k делится пополам. Пробное решение принимается, если все площади остаются положительными, а норма невязки уменьшается по сравнению с предыдущей итерацией. Если хотя бы одно условие не выполняется, шаг уменьшается, и проверка повторяется.

Демпфирование требуется из-за чувствительности связанной задачи. Нейросетевая модель может давать заметное изменение перепада даже при небольшом изменении расхода или скорости. В нестационарном 1D-расчете граничные значения обновляются многократно, поэтому резкие изменения площади и скорости на одном временном шаге нужно ограничивать. Демпфирование позволяет сделать итерационный процесс более устойчивым.

Производные, входящие в матрицу Якоби, вычисляются с учетом зависимости давления, скорости и нейросетевого перепада давления от неизвестных граничных величин. Для нейросетевого модуля аналитическая производная явно не задается, поэтому используется численное приближение производной по расходу или скорости.

Поэтому использование демпфированного метода Ньютона необходимо для устойчивого решения нелинейного узлового условия со стенозом. Нейросетевая модель вносит дополнительную нелинейность в систему, а демпфирование ограничивает размер итерационного шага.

4.4. Расчетный эксперимент и сравнение вариантов интеграции

Для проверки работоспособности интеграции PINN-модуля была использована расчетная схема из двух одномерных сосудов. Первый сосуд располагался до стеноза, второй – после стеноза. Между ними размещался специальный узел `stenosis_pinn`, в котором вычислялся дополнительный перепад давления на основе нейросетевой модели.

Оба сосуда имели одинаковые геометрические параметры: длина каждого сосуда составляла 3,9 см, диаметр – 0,6 см, радиус нормального сосуда – 0,3 см. Диастолическое давление задавалось равным 82 мм рт. ст. Для сосудистой стенки использовались толщина 0,03 см и модуль Юнга 5250. На входе задавался нестационарный расход, соответствующий пульсирующему кровотоку. На выходе использовалась трехэлементная модель Виндкесселя с параметрами $R_1 = 1,8658$, $R_2 = 14,0239$, $C = 0,0234$.

Абсолютный радиус нормального сосуда в расчетном эксперименте 1D-модели отличается от радиуса, использованного при формировании CFD-базы. Это допустимо, поскольку вход нейросетевой модели задается безразмерными параметрами: число Рейнольдса, относительную длину стеноза, степень стеноза и параметр асимметрии. Размерный перепад давления восстанавливается через масштаб ρU^2 . Поэтому нейросеть используется как

безразмерная аппроксимация зависимости перепада давления от режима течения и геометрии стеноза, а абсолютный радиус влияет только на пересчет текущего расхода или скорости в число Рейнольдса.

Расчет выполнялся в течение 3,3 с, что соответствует трем периодам входного сигнала. Период сигнала составлял 1,1 с. Шаг по пространству равен 0,25 см, шаг по времени – 0,0001 с.

Для сравнения были рассмотрены несколько вариантов расчета перепада давления. В качестве базового варианта использовался расчет в одномерной модели без дополнительной нейросетевой поправки. Этот вариант позволяет оценить перепад давления, возникающий только за счет стандартной 1D-формулировки. В базовом варианте 1D-расчета стеноз задавался геометрически как участок сосуда с уменьшенным радиусом, соответствующим выбранной степени сужения. Поэтому даже без нейросетевого модуля перепад давления зависит от степени стеноза за счет изменения площади поперечного сечения и скорости потока.

Отдельно была выполнена проверка PINN без включения в одномерную модель. В этом случае по заданному входному сигналу рассчитывалась средняя скорость потока, после чего соответствующие параметры подавались в нейросеть. Такой расчет не учитывает нестационарное взаимодействие с 1D-моделью, но позволяет оценить порядок величины перепада давления, который предсказывает сама нейросетевая модель.

Далее рассматривалась полная схема 1D+PINN, в которой перепад давления, предсказанный нейросетью, включался в условие сопряжения между участками сосуда. Для определения режима течения использовались два способа. В первом случае скорость для PINN вычислялась через расход Q , полученный из одномерной модели, и фиксированную площадь нормального сосуда, как это делалось при обучении модели. Во втором случае использовалась локальная скорость U , рассчитанная непосредственно в узле сопряжения. В отличие от варианта по расходу, такая скорость зависит от

текущей площади поперечного сечения, изменяющейся во времени из-за упругости сосудистой стенки.

Для схемы 1D+PINN были рассмотрены симметричный и асимметричный варианты геометрии стеноза. Это позволяет оценить влияние параметра асимметрии на перепад давления.

Средний перепад давления определялся как разность средних давлений до стеноза и после стеноза за последний период расчета. Полученные результаты представлены в таблице 4.4.1.

Таблица 4.4.1 – Средний перепад давления за последний период расчета для разных вариантов интеграции PINN-модуля

Степень стеноза по диаметру	1D, (Δp), мм рт. ст.	PINN, (Δp), мм рт. ст.	1D + PINN по (Q), мм рт. ст.	1D + PINN по (U), мм рт. ст.	1D + PINN по (Q), асим., мм рт. ст.	1D + PINN по (U), асим., мм рт. ст.
13%	0,477	0,702	0,750	0,697	0,775	0,715
29%	1,099	1,271	1,370	1,240	1,446	1,302
50%	4,242	4,834	5,330	4,600	6,002	5,110
55%	6,500	7,648	8,470	7,160	9,660	8,040
70%	34,325	37,840	41,042	30,355	46,879	33,932

Из таблицы 4.4.1 видно, что базовая 1D-модель почти во всех случаях дает наименьшие значения перепада давления. При стенозе 13% перепад давления составляет 0,477 мм рт. ст., а при стенозе 70% – 34,325 мм рт. ст. После добавления нейросетевого модуля значения увеличиваются. Добавление нейросетевого модуля вводит в 1D-расчет дополнительную локальную потерю давления, рассчитанную по модели.

Отдельный расчет PINN также дает значения, превышающие результаты базовой 1D-модели: от 0,702 мм рт. ст. при 13% стенозе до 37,84 мм рт. ст. при 70 % стенозе. Это подтверждает, что сама нейросетевая модель воспроизводит рост перепада давления с увеличением степени стеноза.

Исключение наблюдается при стенозе 70% для варианта 1D + PINN по скорости U , где полученное значение ниже результата базовой 1D-модели. Это может быть связано с тем, что при сильном сужении расчёт по скорости становится менее устойчивым и сильнее зависит от локальных значений площади и скорости.

Для сравнения основных вариантов расчета зависимость перепада давления от степени стеноза представлена на рисунке 4.4.1. На графике сравниваются базовая 1D-модель, PINN, схема 1D + PINN с расчетом режима течения по расходу Q и схема 1D + PINN с расчетом режима течения по скорости U .




Рисунок 4.4.1 – Сравнение перепада давления для основных вариантов расчета

Отдельно было рассмотрено влияние асимметрии стеноза. Соответствующие зависимости представлены на рисунке 4.4.2.




Рисунок 4.4.2 – Влияние асимметрии стеноза на перепад давления

Из рисунка 4.4.2 видно, что при малых степенях стеноза различие между симметричным и асимметричным вариантами выражено слабо. Например, при 13% стенозе значение в схеме 1D + PINN по Q увеличивается с 0,75 до 0,775 мм рт. ст., а в схеме по U – с 0,697 до 0,715 мм рт. ст.

При более выраженном стенозе влияние асимметрии становится заметнее. Так, при 55% стенозе значение перепада давления увеличивается с 8,47 до 9,66 мм рт. ст. в варианте по Q и с 7,16 до 8,04 мм рт. ст. в варианте по U .

Расчетный эксперимент показывает работоспособность гибридной схемы 1D-PINN. Встроенный PINN-модуль позволяет учитывать локальный перепад давления на стенозе внутри одномерного расчета. Для всех рассмотренных случаев схема дает физически ожидаемое поведение: перепад давления увеличивается при росте степени стеноза, а асимметричная форма сужения приводит к дополнительному росту потерь давления.

ЗАКЛЮЧЕНИЕ

В выпускной квалификационной работе была рассмотрена задача предсказания перепада давления при сужении просвета сосуда на основе данных CFD-моделирования. Актуальность задачи связана с тем, что геометрическая степень стеноза сама по себе не полностью характеризует его гемодинамическую значимость. Перепад давления зависит не только от степени сужения, но и от режима течения, протяженности стеноза и формы сосудистого просвета, поэтому для его оценки требуется учитывать несколько взаимосвязанных параметров.

Целью работы являлась разработка и исследование нейросетевой модели с физически информированной функцией ошибки для предсказания перепада давления на участке стеноза и интеграция разработанного нейросетевого модуля в одномерную модель гемодинамики. В ходе работы поставленная цель была достигнута.

В теоретической части были рассмотрены механизмы формирования перепада давления при стенозе и основные подходы к его оценке. Это позволило определить параметры, которые далее использовались при построении моделей.

Для получения базового уровня качества были построены модели машинного обучения: линейная регрессия, метод ближайших соседей, градиентный бустинг, случайный лес и XGBoost. Эти модели использовались как ориентир для сравнения с нейросетями. Для линейной регрессии и метода ближайших соседей дополнительно было сформировано расширенное признаковое пространство. В него вошли производные признаки, отражающие нелинейный характер задачи.

Далее были построены две нейросетевые модели: обычная полносвязная нейронная сеть и модель с физически информированной функцией ошибки. Их результаты сравнивались в сопоставимых условиях. Физически информированная составляющая учитывала ожидаемое направление

изменения предсказываемой величины по входным параметрам и ограничение на неотрицательность перепада давления. За счет этого обучение по данным было дополнено априорными сведениями о физически ожидаемом поведении модели в пределах рассматриваемой расчетной области.

Качество моделей оценивалось по метрикам регрессии. На внутренней тестовой выборке лучшие результаты среди классических моделей показали ансамблевые методы на основе деревьев решений. Они хорошо воспроизвели нелинейные зависимости внутри исходной расчетной базы. Нейросетевые модели также показали высокое качество предсказания. Модель с физически информированной функцией ошибки немного улучшила основные метрики по сравнению с обычной полносвязной нейронной сетью, однако различие между ними на внутренней тестовой выборке было умеренным.

Дополнительно модели были проверены на независимом наборе данных. Он использовался для интерполяционной оценки внутри той же расчетной постановки и содержал значения степени стеноза, отсутствующие в обучающей сетке. Проверка показала, что высокая точность на случайной тестовой выборке не всегда сохраняется на независимых данных. Ансамблевые модели, показавшие лучшие результаты на внутреннем тесте, заметно ухудшили качество. Наиболее устойчивыми оказались нейросетевые модели, причем модель с физически информированной функцией ошибки имела небольшое преимущество перед обычной полносвязной сетью. Среди классических методов лучшую интерполяционную способность показали модели с расширенным признаковым пространством.

Для включения нейросетевого модуля в одномерный расчет была разработана схема интеграции. Стеноз рассматривался как локальный элемент дополнительного гидравлического сопротивления между двумя одномерными сосудистыми сегментами. В такой постановке условие сохранения расхода сохраняется, а в баланс полного давления добавляется дополнительная потеря, предсказанная нейросетевой моделью. Были рассмотрены два способа передачи режима течения в нейросетевой модуль: через расход и через

локальную скорость. Расчетный эксперимент показал, что подключение нейросетевого модуля увеличивает перепад давления по сравнению с базовой одномерной моделью. Это соответствует учету дополнительных локальных потерь на стенозе. Также было показано, что асимметрия сужения приводит к увеличению перепада давления, особенно при более выраженных стенозах.

Основным результатом работы является построение и сравнение моделей для предсказания перепада давления при стенозе, а также разработка схемы включения нейросетевого модуля с физически информированной функцией ошибки в одномерный расчет гемодинамики. Нейросетевые модели показали высокое качество предсказания и хорошую интерполяционную способность в пределах рассматриваемой расчетной постановки. Физически информированная функция ошибки оказала положительное, но умеренное влияние на качество модели по сравнению с обычной полносвязной нейронной сетью.

Практическая значимость работы связана с возможностью быстрой приближенной оценки перепада давления на участке стеноза без повторного выполнения полного CFD-расчета. Предложенная схема интеграции нейросетевого модуля в одномерную модель может использоваться как основа для дальнейшего развития гибридных моделей гемодинамики.

Результаты работы имеют ограничения. Модели обучались на данных для идеализированной геометрии сосуда и заданного диапазона параметров, поэтому их применение наиболее обосновано внутри области, представленной в обучающей выборке. Независимый набор данных использовался как интерполяционная проверка внутри той же расчетной постановки и не доказывает применимость модели к произвольным сосудистым геометриям. Гибридная схема была проверена в расчетном эксперименте. Её количественная валидация по нестационарным CFD-расчетам или экспериментальным данным требует отдельного исследования.

Дальнейшее развитие связано с расширением базы CFD-расчетов, использованием более сложных геометрий стеноза и добавлением

нестационарных данных. Также требуется сравнить результаты схемы 1D+PINN с трехмерными CFD-расчетами или экспериментальными измерениями. Что позволит точнее определить область применимости модели.

В работе рассмотрено использование нейросетевой модели с физически информированной функцией ошибки для приближенного предсказания перепада давления при стенозе. Схема 1D+PINN показывает, что локальный перепад давления можно учитывать в одномерном расчете через дополнительное узловое условие.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Baumgartner, H. Recommendations on the Echocardiographic Assessment of Aortic Valve Stenosis: A Focused Update from the European Association of Cardiovascular Imaging and the American Society of Echocardiography / H. Baumgartner, J. Hung, J. Bermejo [et al.]. – Текст : непосредственный // Journal of the American Society of Echocardiography. – 2017. – Vol. 30, № 4. – P. 372–392. – DOI: 10.1016/j.echo.2017.02.009.
2. Brown, D. J. Stenosis Hemodynamics: From Physical Principles to Clinical Indices / D. J. Brown, F. W. K. Smith. – Текст : непосредственный // Journal of Veterinary Internal Medicine. – 2002. – Vol. 16, № 6. – P. 650–657. – DOI: 10.1111/j.1939-1676.2002.tb02403.x.
3. Simakov, S. S. Evaluation of Hemodynamic Significance of Stenosis in Multiple Involvement of the Coronary Vessels by Mathematical Simulation / S. S. Simakov, T. M. Gamilov, F. Yu. Kopylov [et al.]. – Текст : непосредственный // Bulletin of Experimental Biology and Medicine. – 2016. – Vol. 162. – P. 111–114. – DOI: 10.1007/s10517-016-3558-0.
4. Pijls, N. H. J. Measurement of fractional flow reserve to assess the functional severity of coronary-artery stenoses / N. H. J. Pijls, B. De Bruyne, K. Peels [et al.]. – Текст : непосредственный // The New England Journal of Medicine. – 1996. – Vol. 334, № 26. – P. 1703–1708. – DOI: 10.1056/NEJM199606273342604.
5. Young, D. F. Flow characteristics in models of arterial stenoses. I. Steady flow / D. F. Young, F. Y. Tsai. – Текст : непосредственный // Journal of Biomechanics. – 1973. – Vol. 6, № 4. – P. 395–410. – DOI: 10.1016/0021-9290(73)90099-7.
6. Kamangar, S. Numerical Investigation of the Effect of Stenosis Geometry on the Coronary Diagnostic Parameters / S. Kamangar, G. Kalimuthu, I. Anjum Badruddin [et al.]. – Текст : непосредственный // The Scientific World Journal. – 2014. – Vol. 2014. – Article 354946. – DOI: 10.1155/2014/354946.

7. Lyras, K. G. An improved reduced-order model for pressure drop across arterial stenoses / K. G. Lyras, J. Lee. – Текст : непосредственный // PLOS ONE. – 2021. – Vol. 16, № 10. – Article e0258047. – DOI: 10.1371/journal.pone.0258047.
8. Klabunde, R. E. Determinants of Resistance to Flow: Poiseuille's Equation / R. E. Klabunde. – Текст : электронный // Cardiovascular Physiology Concepts. – URL: <https://cvphysiology.com/hemodynamics/h003> (дата обращения: 04.05.2026).
9. Seeley, B. D. Effect of geometry on pressure losses across models of arterial stenoses / B. D. Seeley, D. F. Young. – Текст : непосредственный // Journal of Biomechanics. – 1976. – Vol. 9, № 7. – P. 439–448. – DOI: 10.1016/0021-9290(76)90086-5.
10. Gorlin, R. Hydraulic formula for calculation of the area of the stenotic mitral valve, other cardiac valves, and central circulatory shunts / R. Gorlin, S. G. Gorlin. – Текст : непосредственный // American Heart Journal. – 1951. – Vol. 41, № 1. – P. 1–29. – DOI: 10.1016/0002-8703(51)90002-6.
11. Heys, J. J. Revisiting the Simplified Bernoulli Equation / J. J. Heys, N. Holyoak, A. M. Calleja, M. Belohlavek, H. P. Chaliki. – Текст : непосредственный // The Open Biomedical Engineering Journal. – 2010. – Vol. 4. – P. 123–128. – DOI: 10.2174/1874120701004010123.
12. Jin, W. Arterial pulse wave propagation across stenoses and aneurysms: assessment of one-dimensional simulations against three-dimensional simulations and in vitro measurements / W. Jin, J. Alastruey. – Текст : непосредственный // Journal of The Royal Society Interface. – 2021. – Vol. 18, № 177. – Article 20200881. – DOI: 10.1098/rsif.2020.0881.
13. Taylor, C. A. Computational fluid dynamics applied to cardiac computed tomography for noninvasive quantification of fractional flow reserve: scientific basis / C. A. Taylor, T. A. Fonte, J. K. Min. – Текст : непосредственный // Journal of the American College of Cardiology. – 2013. – Vol. 61, № 22. – P. 2233–2241. – DOI: 10.1016/j.jacc.2012.11.083.

14. Zhong, L. Application of Patient-Specific Computational Fluid Dynamics in Coronary and Intra-Cardiac Flow Simulations: Challenges and Opportunities / L. Zhong, J. M. Zhang, B. Su [et al.]. – Текст : непосредственный // *Frontiers in Physiology*. – 2018. – Vol. 9. – Article 742. – DOI: 10.3389/fphys.2018.00742.
15. ANSYS. Cardiovascular & Blood Flow Simulation Software. – Текст : электронный. – URL: <https://www.ansys.com/applications/cardiovascular> (дата обращения: 04.05.2026).
16. Thomas, B. Patient Specific Modelling of Blood Flow in Coronary Artery / B. Thomas, K. S. Sumam, N. Sajikumar. – Текст : непосредственный // *Journal of Applied Fluid Mechanics*. – 2021. – Vol. 14, № 5. – P. 1469–1482. – DOI: 10.47176/jafm.14.05.32186.
17. Koo, B. K. Diagnosis of ischemia-causing coronary stenoses by noninvasive fractional flow reserve computed from coronary computed tomographic angiograms / B. K. Koo, A. Erglis, J. H. Doh [et al.]. – Текст : непосредственный // *Journal of the American College of Cardiology*. – 2011. – Vol. 58, № 19. – P. 1989–1997. – DOI: 10.1016/j.jacc.2011.06.066.
18. Food and Drug Administration. De Novo Summary: HeartFlow FFRCT, DEN130045. – Текст : электронный. – 2014. – URL: https://www.accessdata.fda.gov/cdrh_docs/reviews/DEN130045.pdf (дата обращения: 04.05.2026).
19. National Institute for Health and Care Excellence. HeartFlow FFRCT for estimating fractional flow reserve from coronary CT angiography : HealthTech guidance HTG429. – Текст : электронный. – Published 13 February 2017, last reviewed 19 May 2021. – URL: <https://www.nice.org.uk/guidance/htg429> (дата обращения: 04.05.2026).
20. Food and Drug Administration. Reporting of Computational Modeling Studies in Medical Device Submissions: Guidance for Industry and Food and Drug Administration Staff. – Текст : электронный. – 2016. – URL: <https://www.fda.gov/regulatory-information/search-fda-guidance->

documents/reporting-computational-modeling-studies-medical-device-submissions
(дата обращения: 04.05.2026).

21. Food and Drug Administration. Assessing the Credibility of Computational Modeling and Simulation in Medical Device Submissions: Guidance for Industry and Food and Drug Administration Staff. – Текст : электронный. – 2023. – URL: <https://www.fda.gov/regulatory-information/search-fda-guidance-documents/assessing-credibility-computational-modeling-and-simulation-medical-device-submissions> (дата обращения: 04.05.2026).

22. Sacks, J. Design and analysis of computer experiments / J. Sacks, W. J. Welch, T. J. Mitchell, H. P. Wynn. – Текст : непосредственный // Statistical Science. – 1989. – Vol. 4, № 4. – P. 409–423. – DOI: 10.1214/ss/1177012413.

23. Taebi, A. Deep Learning for Computational Hemodynamics: A Brief Review of Recent Advances / A. Taebi. – Текст : непосредственный // Fluids. – 2022. – Vol. 7, № 6. – Article 197. – DOI: 10.3390/fluids7060197.

24. Gamilov, T. Computational Analysis of Hemodynamic Indices Based on Personalized Identification of Aortic Pulse Wave Velocity by a Neural Network / T. Gamilov, F. Liang, P. Kopylov [et al.]. – Текст : непосредственный // Mathematics. – 2023. – Vol. 11, № 6. – Article 1358. – DOI: 10.3390/math11061358.

25. Cover, T. M. Nearest Neighbor Pattern Classification / T. M. Cover, P. E. Hart. – Текст : непосредственный // IEEE Transactions on Information Theory. – 1967. – Vol. 13, № 1. – P. 21–27. – DOI: 10.1109/TIT.1967.1053964.

26. Breiman, L. Random Forests / L. Breiman. – Текст : непосредственный // Machine Learning. – 2001. – Vol. 45. – P. 5–32. – DOI: 10.1023/A:1010933404324.

27. Friedman, J. H. Greedy Function Approximation: A Gradient Boosting Machine / J. H. Friedman. – Текст : непосредственный // The Annals of Statistics. – 2001. – Vol. 29, № 5. – P. 1189–1232. – DOI: 10.1214/aos/1013203451.

28. Chen, T. XGBoost: A Scalable Tree Boosting System / T. Chen, C. Guestrin. – Текст : непосредственный // Proceedings of the 22nd ACM SIGKDD

International Conference on Knowledge Discovery and Data Mining. – 2016. – P. 785–794. – DOI: 10.1145/2939672.2939785.

29. Goodfellow, I. Deep Learning / I. Goodfellow, Y. Bengio, A. Courville. – Текст : непосредственный. – Cambridge : MIT Press, 2016.

30. Raissi, M. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations / M. Raissi, P. Perdikaris, G. E. Karniadakis. – Текст : непосредственный // Journal of Computational Physics. – 2019. – Vol. 378. – P. 686–707. – DOI: 10.1016/j.jcp.2018.10.045.

31. Cai, S. Physics-informed neural networks (PINNs) for fluid mechanics: a review / S. Cai, Z. Mao, Z. Wang, M. Yin, G. E. Karniadakis. – Текст : непосредственный // Acta Mechanica Sinica. – 2021. – Vol. 37. – P. 1727–1738. – DOI: 10.1007/s10409-021-01148-1.

32. Kissas, G. Machine learning in cardiovascular flows modeling: Predicting arterial blood pressure from non-invasive 4D flow MRI data using physics-informed neural networks / G. Kissas, Y. Yang, E. Hwuang, W. R. Witschey, J. A. Detre, P. Perdikaris. – Текст : непосредственный // Computer Methods in Applied Mechanics and Engineering. – 2020. – Vol. 358. – Article 112623. – DOI: 10.1016/j.cma.2019.112623.

33. Arzani, A. Uncovering near-wall blood flow from sparse data with physics-informed neural networks / A. Arzani, J.-X. Wang, R. M. D'Souza. – Текст : непосредственный // Physics of Fluids. – 2021. – Vol. 33, № 7. – Article 071905. – DOI: 10.1063/5.0055600.

34. Alzhanov, N. Three-Dimensional Physics-Informed Neural Network Simulation in Coronary Artery Trees / N. Alzhanov, E. Y. K. Ng, Y. Zhao. – Текст : непосредственный // Fluids. – 2024. – Vol. 9, № 7. – Article 153. – DOI: 10.3390/fluids9070153.

35. Zhang, X. Physics-informed neural networks (PINNs) for 4D hemodynamics prediction: An investigation of optimal framework based on vascular morphology / X. Zhang, B. Mao, Y. Che, J. Kang, G. Li. – Текст :

непосредственный // Computers in Biology and Medicine. – 2023. – Vol. 164. – Article 107287. – DOI: 10.1016/j.compbimed.2023.107287.

36. Abbasi, J. Physical activation functions (PAFs): An approach for more efficient induction of physics into physics-informed neural networks (PINNs) / J. Abbasi, P. O. Andersen. – Текст : непосредственный // Neurocomputing. – 2024. – Vol. 608. – Article 128352. – DOI: 10.1016/j.neucom.2024.128352.

37. Deuflhard, P. A modified Newton method for the solution of ill-conditioned systems of nonlinear equations with application to multiple shooting / P. Deuflhard. – Текст : непосредственный // Numerische Mathematik. – 1974. – Vol. 22. – P. 289–315. – DOI: 10.1007/BF01406969.

38. Hastie, T. The Elements of Statistical Learning: Data Mining, Inference, and Prediction / T. Hastie, R. Tibshirani, J. Friedman. – Текст : непосредственный. – 2nd ed. – New York : Springer, 2009.

39. James, G. An Introduction to Statistical Learning: with Applications in R / G. James, D. Witten, T. Hastie, R. Tibshirani. – Текст : непосредственный. – 2nd ed. – New York : Springer, 2021.

40. Rumelhart, D. E. Learning representations by back-propagating errors / D. E. Rumelhart, G. E. Hinton, R. J. Williams. – Текст : непосредственный // Nature. – 1986. – Vol. 323. – P. 533–536. – DOI: 10.1038/323533a0.

41. Baydin, A. G. Automatic Differentiation in Machine Learning: A Survey / A. G. Baydin, B. A. Pearlmutter, A. A. Radul, J. M. Siskind. – Текст : непосредственный // Journal of Machine Learning Research. – 2018. – Vol. 18, № 153. – P. 1–43.

42. Kingma, D. P. Adam: A Method for Stochastic Optimization / D. P. Kingma, J. Ba. – Текст : непосредственный // Proceedings of the 3rd International Conference on Learning Representations. – 2015.

43. Simakov, S. Computational study of blood flow in lower extremities under intense physical load / S. Simakov, T. Gamilov, Y. N. Soe. – Текст : непосредственный // Russian Journal of Numerical Analysis and Mathematical Modelling. – 2013. – Vol. 28, № 5. – P. 485–504. – DOI: 10.1515/nam-2013-0027.

44. Armijo, L. Minimization of functions having Lipschitz continuous first partial derivatives / L. Armijo. – Текст : непосредственный // Pacific Journal of Mathematics. – 1966. – Vol. 16, № 1. – P. 1–3. – DOI: 10.2140/pjm.1966.16.1.

45. Moré, J. J. Line search algorithms with guaranteed sufficient decrease / J. J. Moré, D. J. Thuente. – Текст : непосредственный // ACM Transactions on Mathematical Software. – 1994. – Vol. 20, № 3. – P. 286–307. – DOI: 10.1145/192115.192132.

Выпускная квалификационная работа на тему «Физически-информированная нейронная сеть для оценки перепада давлений в области сужения просвета сосуда» выполнена мной самостоятельно. Все использованные в работе материалы и положения из научной литературы и других источников имеют ссылки на них.

Список использованных источников содержит 45 наименований.

ВКР сдана на кафедру « » 20 г.

Автор ВКР

(подпись)

(Ф.И.О.)